



**BEYİN T M R  TESP T  İ İN DERİN   RENME İLE
MR G R NT LERİNİN B L TLENMESİ**

İbrahim KILI 

**Y. Lisans Tezi
Elektrik-Elektronik Anabilim Dalı
Elektronik Bilim Dalı
Dr.   r.  yesi Emin Argun ORAL
2019
Her hakkı saklıdır**

**ATATÜRK ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ**

YÜKSEK LİSANS TEZİ

**BEYİN TÜMÖRÜ TESPİTİ İÇİN DERİN ÖĞRENME İLE MR
GÖRÜNTÜLERİNİN BÖLÜTLENMESİ**

İbrahim KILIÇ

**ELEKTRİK-ELEKTRONİK MÜH. ANABİLİM DALI
Elektronik Bilim Dalı**

**ERZURUM
2019**

Her hakkı saklıdır



TEZ ONAY FORMU

**BEYİN TÜMÖRÜ TESPİTİ İÇİN DERİN ÖĞRENME İLE MR
GÖRÜNTÜLERİNİN BÖLÜTLENMESİ**

Dr. Öğr. Üyesi Emin Argun ORAL danışmanlığında, İbrahim KILIÇ tarafından hazırlanan bu çalışma, 09/01/2019 tarihinde aşağıdaki jüri tarafından Elektrik-Elektronik Mühendisliği Anabilim Dalı Elektronik Bilim Dalı'nda Yüksek Lisans tezi olarak **oybirliği** ile kabul edilmiştir.

Başkan: Doç. Dr. İ. Yücel ÖZBEK

İmza :

Üye : Dr. Öğr. Üyesi Kağan Koray AYTEN

İmza :

Üye : Dr. Öğr. Üyesi Emin Argun ORAL

İmza :

Yukarıdaki sonuç;

Enstitü Yönetim Kurulu'nun **14.02/2019** tarih ve **.08..../.23.....** nolu kararı ile onaylanmıştır.


Prof. Dr. Mehmet KARAKAN
Enstitü Müdürü

Not: Bu tezde kullanılan özgün ve başka kaynaklardan yapılan bildiriş, çizelge, şekil ve fotoğrafların kaynak olarak kullanımı, 5846 sayılı Fikir ve Sanat Eserleri Kanunundaki hükümlere tabidir.

ÖZET

Yüksek Lisans Tezi

BEYİN TÜMÖRÜ TESPİTİ İÇİN DERİN ÖĞRENME İLE MR GÖRÜNTÜLERİNİN BÖLÜTLENMESİ

İbrahim KILIÇ

Atatürk Üniversitesi
Fen Bilimleri Enstitüsü
Elektrik-Elektronik Anabilim Dalı
Elektronik Bilim Dalı

Danışman: Dr. Öğr. Üyesi Emin Argun ORAL

Beyin tümörlerinin büyüklüğü ve boyutlarının belirlenmesi teşhis ve tedavide oldukça zaman alıcı ve zahmetli bir iş olduğu bilinmektedir. MRG görüntüleri beyin tümörlerinin tespit edilmesinde en önemli yöntemlerden biridir. Ancak MRG görüntülerinde tümörlerin hacimsel büyüklükleri otomatik olarak belirlenememektedir. Bunu belirlemek için manuel yöntemler kullanılmaktadır. Bu da zaman ve emek açısından hayli zahmetli bir işlemdir. Bu çalışmada U-Net tabanlı bir CNN ağı kullanarak beyin tümörlerinin hacimsel segmentasyonu yapılmaya çalışılmıştır. Bu çalışma, BRATS 2017 veri seti kullanılarak eğitilip daha sonra test ve doğrulama işlemi yapılmıştır. Elde edilen sonuçlardan yola çıkarak yapılan çalışmanın beyin tümörlerinin segmentasyonu işleminde oldukça başarılı olduğu görülmüştür. Bu da çalışmamızın daha da geliştirildikten sonra otomatik olarak beyin tümörlerinin segmentasyon işlemini yapacağı ortaya çıkmıştır.

2019, 62 sayfa

Anahtar Kelimeler: Segmentasyon, MRG, CNN, U-Net

ABSTRACT

MS Thesis

SCREENING THE MR IMAGES WITH DEEP LEARNING FOR DETERMINATION OF BRAIN TUMOR İbrahim KILIÇ

Atatürk University
Graduate School of Natural and Applied Sciences
Department of Electrical-Electronics

Supervisor : Dr. Öğr. Üyesi Emin Argun ORAL

Determination of the size of brain tumors is known to be a time consuming and troublesome work in diagnosis and treatment. MRI images are one of the most important methods for detecting brain tumors. However, the volume magnitudes of tumors can not be determined automatically on MRI images. Manual methods are used to determine this. This is a time-consuming and labor-intensive process. In this study, volumetric segmentation of brain tumors was attempted using a U-Net based CNN network. This study was trained using the BRATS 2017 data set and then tested and verified. From the results obtained, it has been seen that the study done by going out of the way is quite successful in the segmentation of brain tumors. This means that our brain will be automatically segmented after our work is further improved

2019, 62 pages

Keywords : Segmentation, MRI, CNN, U-Net

TEŞEKKÜR

Bu tez çalışmasının ortaya çıkmasında fikirleriyle bana ışık tutan, tecrübesini benden esirgemeyen ve bana yol gösteren saygıdeğer hocam ve danışmanım Sayın Dr. Öğr. Üyesi Emin Argun ORAL' a ve Doç. Dr. İbrahim Yücel ÖZBEK' e tüm katkılarından dolayı teşekkür ederim.

Ayrıca yoğun zamanlarımda bana karşı anlayışlı davranan ve manevi desteğini hiç esirgemeyen eşim Hülya KILIÇ 'a, çocuklarım Muhammed Efe KILIÇ ve Mehmet Enes KILIÇ' a teşekkür ederim.

İbrahim KILIÇ

Şubat, 2019

İÇİNDEKİLER

| | |
|---|----------------------------------|
| ÖZET | Hata! Yer işareti tanımlanmamış. |
| ABSTRACT..... | ii |
| TEŞEKKÜR..... | iii |
| SİMGELER ve KISALTMALAR DİZİNİ | vii |
| ŞEKİLLER..... | viii |
| ÇİZELGELER..... | xi |
| 1. GİRİŞ..... | 1 |
| 2. KAYNAK ARAŞTIRMASI..... | 4 |
| 3. MATERYAL ve YÖNTEM..... | 7 |
| 3.1. Beyin Tümörleri..... | 7 |
| 3.1.1 Beyin Tümörünün Belirtileri | 7 |
| 3.1.2 Beyin Tümörünün Çeşitleri | 8 |
| 3.1.3 Beyin Tümörlerinin Sınıflandırılması | 9 |
| 3.1.3.1 Hipofiz adenomları..... | 9 |
| 3.1.3.2 Beyin Zarı Tümörleri | 9 |
| 3.1.3.3 Metastatik Tümörler..... | 10 |
| 3.1.3.4 Köşe Tümörleri | 10 |
| 3.1.3.5 Beyin Dokusu Tümörler..... | 10 |
| 3.1.4 Beyin Tümörleri Tespitinde Kullanılan Yöntemler | 10 |
| 3.2 MR | 11 |
| 3.2.1 Beyin MR nedir? | 11 |
| 3.2.2 Beyin MR Çekimi Neler Gösterir?..... | 11 |
| 3.3 Derin Öğrenme Nedir?..... | 12 |
| 3.3.1 Derin Öğrenme Neden Önemlidir? | 13 |
| 3.3.2 Derin Öğrenme Nasıl Çalışır? | 13 |
| 3.4 Evrişimli Sinir Ağları (Cnns/Convnets) | 14 |
| 3.4.1 Mimariye Genel Bakış | 14 |

| | | |
|----------|--|-----------|
| 3.4.2 | Üç boyutlu Nöronlar..... | 15 |
| 3.4.3 | İki Boyutlu Evrişim (2D Convolüsyon) | 16 |
| 3.4.4 | Kenar Bulma..... | 18 |
| 3.4.5 | Dolgulama (Padding) | 19 |
| 3.4.6 | Kaydırma Adımı (Stride)..... | 20 |
| 3.4.7 | Ortaklama (Pooling) | 21 |
| 3.5 | Ağ Modelleri..... | 21 |
| 3.5.1 | LeNet-5..... | 22 |
| 3.5.2 | AlexNet Modeli | 22 |
| 3.5.3 | VGG-16 | 23 |
| 3.5.4 | ResNet | 24 |
| 3.5.5 | Ağ İçinde Ağ | 25 |
| 3.5.6 | Inception Ağlar (GoogLeNet) | 25 |
| 3.5.7 | Transfer Öğrenme..... | 26 |
| 3.5.8 | Veri Artırma (Data Augmentation) | 27 |
| 3.6 | Derin Öğrenme Uygulamalarında Kullanılan Hiperparametreler | 28 |
| 3.6.1 | Veri Seti..... | 28 |
| 3.6.2 | “Mini-Batch” Boyutu | 29 |
| 3.6.3 | Öğrenme Hızı ve Momentum Katsayısı | 31 |
| 3.6.4 | Optimizasyon Değerlerinin Belirlenmesi | 32 |
| 3.6.5 | Epoch (Eğitim tur) Sayısı | 33 |
| 3.6.6 | Başlangıçtaki Ağırlık Değerlerinin Saptanması | 34 |
| 3.6.7 | Aktivasyon İşlemleri | 34 |
| 3.6.8 | Seyreltme İşlemleri..... | 35 |
| 3.6.9 | Katman Sayısı ve Nöron Sayısı..... | 36 |
| 3.6.10 | Konvolüsyon Sinir Ağı (CNN) Kernel Boyutu..... | 38 |
| 4 | ARAŞTIRMA BULGULARI ve TARTIŞMA | 39 |
| 4.1 | Kullanılan Veri Tabanı ve Özellikleri | 39 |
| 4.2 | Veri Büyütme..... | 39 |
| 4.3 | U-Net Tabanlı Derin Dönüşümlü Ağlar | 40 |
| 4.4 | Eğitim ve Optimizasyon | 41 |
| 4.5 | Performans Ölçütleri..... | 42 |
| 4.6 | DeneySEL Sonuçlar | 43 |

| | |
|-----------------------|-----------|
| 4.7. Tartışma | 65 |
| 5. SONUÇ | 67 |
| KAYNAKÇA | 68 |
| ÖZGEÇMİŞ..... | 71 |



SİMGELER ve KISALTMALAR DİZİNİ

| | |
|----|----------------------|
| N | Giriş matrisi |
| P | Piksel ekleme değeri |
| F | Filtre matrisi |
| S | Adım sayısı |
| W | Ağırlık |
| Tp | Gerçek Pozitif |
| Fp | Yanlış pozitif |
| Fn | Yanlış negatif |

Kısaltmalar

| | |
|---------|-------------------------------|
| MR | Magnetic Resonance |
| BBB | Blood Brain Barrier |
| LGG | Low grade Gliomas |
| HGG | High Grade Gliomas |
| MRI | Magnetic Resonance Imaging |
| CNN | Convolutional Neural Networks |
| BRATS | Brain Tumor Segmentation |
| GPU | Grafik Proses Unit |
| CONVNET | Convolutional Networks |
| RGB | Red-Green-Blue |
| FC | Fully Connected |
| SGD | Stochastic Gradient Descent |
| DSC | Dice Similarity Coefficient |

ŞEKİLLER

| | |
|--|----|
| Şekil 3. 1. Düzenli 3 katmanlı bir Sinir Ağı. Sağ: Bir ConvNet, nöronlarını katmanlardan birinde görselleştirildiği gibi üç boyutta (genişlik, yükseklik, derinlik) düzenler. | 15 |
| Şekil 3. 2. İki boyutlu evrişim işlemi gösterimi..... | 16 |
| Şekil 3. 3. Yatay ve Dikey Filtreleme İşlemi..... | 17 |
| Şekil 3. 4. Convolutional Neural Networks (Recognition 2017) | 17 |
| Şekil 3. 5. Şekil 5: Yatay ve Dikey Kenar Bulma (Anonim 2016)..... | 18 |
| Şekil 3. 6. Piksel Ekleme | 19 |
| Şekil 3. 7. Kaydırma Adımı Gösterimi | 20 |
| Şekil 3. 8. Max Pooling Gösterimi..... | 21 |
| Şekil 3. 9. LeNet-5 Modeli (Kızrak.A 2018)..... | 22 |
| Şekil 3. 10. AlexNet Modeli (Anonim 2018) | 23 |
| Şekil 3. 11. VGG-16 Modeli (Anonim 2018)..... | 24 |
| Şekil 3. 12. GoogleNet Modeli (Anonim 2018) | 25 |
| Şekil 3. 13. GoogleNet Genel Gösterimi | 26 |
| Şekil 3. 14. Veri Büyütme Gösterimi..... | 27 |
| Şekil 3. 15. Veri Büyütme Gösterimi-2 | 28 |
| Şekil 3. 16. Mini-batch sonrası hata değeri değişimi..... | 29 |
| Şekil 3. 17. Bazı optimizasyon algoritmalarının çalışma zamanı grafiği (Ruder.S 2017) | 32 |
| Şekil 3. 18. Bazı aktivasyon fonksiyonlarının grafikleri | 35 |
| Şekil 3. 19. Dropout İşlemi (Scheau.C 2016). | 36 |

| | |
|--|----|
| Şekil 3. 20. Yapay Sinir Ağı (Parbhakar.A 2016). | 37 |
| Şekil 3. 21. Örnek Evrişimsel Sinir Ağı (CNN) Yapısı (Anonim 2018) | 38 |
| Şekil 4. 1. U-Net modeli (Dong, Yang et al. 2017) | 41 |
| Şekil 4. 2. Sol: Eğitim sonucunda elde edilmiş ağ ile tek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafından oluşturulan etiket. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi) | 45 |
| Şekil 4. 3. Sol: Eğitim sonucunda elde edilmiş ağ ile tek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafından oluşturulan etiket. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi) | 47 |
| Şekil 4. 4. Sol: Eğitim sonucunda elde edilmiş ağ ile tek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafından oluşturulan etiket. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi) | 48 |
| Şekil 4. 5. Sol: Eğitim sonucunda elde edilmiş ağ ile tek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafından oluşturulan etiket. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi) | 51 |
| Şekil 4. 6. Sol: Eğitim sonucunda elde edilmiş ağ ile tek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafından oluşturulan etiket. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi) | 53 |
| Şekil 4. 7. Sol: Eğitim sonucunda elde edilmiş ağ ile tek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafından oluşturulan etiket. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi) | 55 |
| Şekil 4. 8. Sol: Eğitim sonucunda elde edilmiş ağ ile tek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafından oluşturulan etiket. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi) | 57 |

| | |
|--|----|
| Şekil 4. 9. Sol: Eğitim sonucunda elde edilmiş ağ ile tek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiket. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi) | 59 |
| Şekil 4. 10. Sol: Eğitim sonucunda elde edilmiş ağ ile tek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiket. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi) | 61 |
| Şekil 4. 11. Sol: Eğitim sonucunda elde edilmiş ağ ile tek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiket. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi) | 63 |

ÇİZELGELER

| | |
|---|----|
| Çizelge 4.1. Test 1 model eğitiminde kullanılan parametreler | 43 |
| Çizelge 4.2. HGG ve LGG verileri için 25 epoch ile elde edilen test sonuçları | 44 |
| Çizelge 4.3. HGG ve LGG verileri için 25 epoch ile elde edilen üç bölge test sonuçları | 44 |
| Çizelge 4.4. Test 2 model eğitiminde kullanılan parametreler | 45 |
| Çizelge 4.5. HGG verileri için 20 epoch ile elde edilen test sonuçları | 46 |
| Çizelge 4. 6. HGG verileri için 20 epoch ile elde edilen üç bölge test sonuçları | 46 |
| Çizelge 4.7. Test 3 model eğitiminde kullanılan parametreler | 47 |
| Çizelge 4.8. LGG verileri için 20 epoch ile elde edilen test sonuçları | 48 |
| Çizelge 4.9. LGG verileri için 20 epoch ile elde edilen üç bölge test sonuçları | 48 |
| Çizelge 4.10. Test 4 model eğitiminde kullanılan parametreler | 49 |
| Çizelge 4.11. HGG ve LGG verileri için 20 epoch ile elde edilen test sonuçları | 50 |
| Çizelge 4.12. HGG ve LGG verileri için 20 epoch ile elde edilen üç bölge test sonuçları | 50 |
| Çizelge 4.13. Test 5 model eğitiminde kullanılan parametreler | 51 |
| Çizelge 4.14. HGG verileri için 50 epoch ile elde edilen test sonuçları | 52 |
| Çizelge 4.15. HGG verileri için 50 epoch ile elde edilen üç bölge test sonuçları | 52 |
| Çizelge 4.16. Test 6 model eğitiminde kullanılan parametreler | 53 |
| Çizelge 4.17. LGG verileri için 50 epoch ile elde edilen test sonuçları | 54 |
| Çizelge 4. 18. LGG verileri için 50 epoch ile elde edilen üç bölge test sonuçları | 54 |
| Çizelge 4.19. Test 7 model eğitiminde kullanılan parametreler | 55 |

| | |
|---|----|
| Çizelge 4.20. HGG ve LGG verileri için 50 epoch ile elde edilen test sonuçları..... | 56 |
| Çizelge 4.21. HGG ve LGG verileri için 50 epoch ile elde edilen üç bölge test sonuçları | 56 |
| Çizelge 4.22. Test 7 model eğitiminde kullanılan parametreler | 57 |
| Çizelge 4.23. HGG verileri için 100 epoch ile elde edilen test sonuçları..... | 58 |
| Çizelge 4.24. HGG verileri için 100 epoch ile elde edilen üç bölge test sonuçları | 58 |
| Çizelge 4.25. Test 8 model eğitiminde kullanılan parametreler | 59 |
| Çizelge 4.26. LGG verileri için 100 epoch ile elde edilen test sonuçları | 60 |
| Çizelge 4.27. LGG verileri için 100 epoch ile elde edilen üç bölge test sonuçları..... | 60 |
| Çizelge 4. 28. Test 9 model eğitiminde kullanılan parametreler | 61 |
| Çizelge 4. 29. HGG ve LGG verileri için 100 epoch ile elde edilen test sonuçları..... | 62 |
| Çizelge 4. 30. HGG ve LGG verileri için 100 epoch ile elde edilen üç bölge test sonuçları | 62 |
| Çizelge 4. 31. Yapılan tüm testlerin Doğruluk Skoru sonuçları | 63 |
| Çizelge 4. 32. Yapılan tüm testlerin IoU sonuçları..... | 64 |

1. GİRİŞ

Birinci derecede malign beyin tümörleri insan yaşamını olumsuz yönde etkileyen tümör çeşitlerinin başında gelmektedir. Yetişkinlerde en fazla görülen kanser türlerinin başında enfomalar ve gliomalar gelmektedir. Bunlar kanserlerin yaklaşık %80' nini oluşturur (Schwartzbaum, Fisher et al. 2006). Gliomalar hem yüksek dereceli tümörleri (HGG), hem de düşük dereceli tümörleri (LGG) kapsamaktadır. HGG türü tümörlere sahip hastaların ancak %2 ile %8' i ancak 10 yıl yaşamını sürdürebilmektedirler (Smoll, Schaller et al. 2013). LGG türü tümörler de ise bu durum biraz daha farklıdır ve 10 yıl süre yaşayanların oranı %57 seviyelerindedir (Ramakrishna, Hebb et al. 2015).

Beyin tümörlerinin tespit edilmesinde MR görüntüleme yönteminin büyük katkısı vardır. Bu yöntem tümörle ilgili çok önemli veriler elde etmemizi sağlar. Beyin MR' larının çekilmesinde bazı sekanslar kullanılır. Bu sekanslar T1, T1c(T1 kontrastlı), T2 ve FLAIR olarak bilinmektedir. Bu sekanslar ile çekilen beyin MR görüntüleri farklı tümörlerin farklı bölgelerde tespit edilmesini sağlamaktadır (Jones, Byrnes et al. 2014).

MR görüntülerinde tümörlerin segmentasyonu teşhis ve tedavide büyük önem taşımaktadır. Segmentasyon sonucun elde edilen görüntünün hacimsel boyutları kullanılarak tümörün sınıflandırılması yapılabilir. Tümörün hangi çeşit olduğu, ilerleyen veya ilerlemeyen tümör olduğu vb. bilgiler elde edilebilir. Elde edilen verilerle teşhis ve tedavinin yapılması kolaylaşabilir. Segmentasyon işlemi genellikle uzmanlar tarafından manuel olarak yapılmaktadır. Bu işlemler hasta sayısına göre çok zaman ve emek istemektedir. Ayrıca segmentasyon, bu işlemi yapan kişiye göre de farklı yorumlanabilir. Farklı uzmanlar tarafından teşhis ve tedavinin farklı şekilde yapılacağı anlamına gelmektedir. Fakat segmentasyon işlemi otomatik olarak bir algoritmaya yaptırılması bu alanda çok kolaylık sağlayabilir ve güvenilirliği artırır.

Yapılan çalışmalarda otomatik segmentasyon işlemi oldukça ilerlemiştir. Fakat tümörün boyutu, şekli ve karmaşık bir yapıya sahip olması nedeniyle bazı sorunlar ortaya çıkmaktadır. Bu sorunlar:

1. BBB normal olarak LGG vakalarında bozulmadan kalır ve tümör bölgeleri genellikle kontrast artırmaz. Bu nedenle, LGG'nin sınırları, FLAIR sekansı, lezyonun tam kapsamını tanımlamak için normal beyin ve beyin tümörü veya ödemi arasında farklılaşma sağlamasına rağmen görünmez veya bulanık olabilir.
2. Aksine, yüksek dereceli gliomalar (HGG) vakaları için, kontrast madde, örneğin Gadolinyum, parçalanmış BBB boyunca sızıntı yapar ve T1 ağırlıklı görüntülerde hiperintensiteye neden olan beyin tümörünün hücre dışı boşluğuna girer. Bu nedenle nekroz ve aktif tümör bölgeleri kolaylıkla tanımlanabilir. Bununla birlikte, HGG genellikle agresif tümör infiltrasyonu nedeniyle süreksizlikleri de içerebilecek belirsiz ve düzensiz sınırlar sergiler. Bu, sorunlara neden olabilir ve zayıf tümör segmentasyonuna yol açabilir.
3. Tümör alt bölgelerini değiştirebilir ve tümör tipleri sadece multimodal MRI verileri dikkate alınarak görülebilir. Bununla birlikte, çoklu MRI dizileri boyunca ortak tescil, özellikle bu diziler farklı uzamsal çözünürlüklerde elde edildiğinde zor olabilir.
4. Tipik klinik MRG görüntüleri normal olarak, daha iyi kesitsel görünüm ve sınırlı tarama süresi ile Ödem hacmini kaplayacak yeterli görüntü dilimleri arasında denge kurmak için daha yüksek düzlem içi çözünürlük ve çok daha düşük dilimli çözünürlük ile elde edilir. Bu, yetersiz sinyal/gürültü oranına neden olabilir ve asimetrik kısmi hacim etkileri de son segmentasyon doğruluğunu etkileyebilir (Dong, Yang et al. 2017).

Evrişimli sinir ağıları (CNN), beyin tümörü segmentasyon yöntemlerin de sık sık kullanılmaya başlanmıştır. Bu yöntemle beyin tümörlerinin segmentasyon işleminde yüksek seviyelerde başarı sağlandığı görülmüştür. Fakat bu yöntemde de bazı zorluklarla karşılaşmaktadır. Bunlardan en önemlileri tümör segmentasyonun da istenmeyen

sapmaların olması, HGG görüntülerinde segmentasyonun yüksek seviyelerde başarının yakalanması ancak LGG görüntülerinde aynı başarının yakalanmaması ve çekirdek tümör olarak adlandırılan tümörlerin tam olarak tespit edilememesi olarak söylenebilir.

Bu çalışmada 2 boyutlu MR görüntülerini U-Net mimarisi kullanarak segmentasyon işleminin yapılması amaçlanmıştır. Çalışma da BRATS 2017 veri seti kullanılmıştır. Verilerin daha fazla olması doğruluk ve güvenilirliği artıracak için ağıımızda veri büyütme işlemi yapılmıştır. Çalışmamız yine BRATS 2017 veri seti kullanılarak test edilmiş ve sonuçları gözlemlenmiştir.



2. KAYNAK ARAŞTIRMASI

Günümüzde Türkiye’de ve Dünya’da her yıl çok sayıda insanın kanser ve özellikle de yetişkinlerde en sık görülen türlerden olan beyin tümörü teşhisi almalarından dolayı bu alanda yapılan çalışmalar da çeşitlidir. Bu çalışmaların bir alanı da beyin tümörlerinin sınıflandırılması alanında yürütülmektedir. Beyin tümörlerinin tespit edilmesinde genellikle Manyetik Rezonans Görüntüleme (MRI) tekniği kullanılmaktadır. Bu görüntüler sınıflandırılırken farklı yöntemler ve teknikler kullanılmaktadır. Bunları üç sınıfta değerlendirebiliriz.

İlk olarak elde edilen görüntüler uzmanlar tarafından (manuel) değerlendirilerek sınıflandırılırlar. Arekeri vd (2013)’na göre uzmanlar tarafından yapılan doğru sınıflandırma oranı %75 civarında olduğunu söylemişlerdir.

İkinci olarak bilgisayar destekli (makine öğrenme) sınıflandırma yöntemleri son zamanlarda çok fazla kullanılmaktadır. Fletcher vd (2001) FCM (Bulanık C-Ortalama) yöntemini kullanarak MR görüntülerinin sınıflandırmak için bir yöntem geliştirmişlerdir.

Joung vd (2010) k-means yöntemini önermişlerdir. Fakat FCM (Bulanık C-Ortalama) yönteminin daha başarılı olduğunu belirtmişlerdir.

Kurat ve Özkaya (2014) MR görüntülerini kullanarak beyin tümörlerinin yerlerini ve boyutlarını otomatik olarak tespit etmeye çalışmışlardır. %70 civarında başarı oranına ulaştıklarını belirtmişlerdir.

Liu vd (2014) tarafından 3D-MET (Three Dimensional Minimum Error Thresholding) yöntemi 3 boyutlu gri tonlamalı MR görüntüleri için önerilmiş ve başarılı sonuçlar aldıklarını söylemişlerdir.

Bhandari vd (2014) Cuckoo ve WDO (Wind Driven Optimization) yöntemlerini Kapur entropi yöntemi ile birleştirerek çok seviyeli bölütleme yaklaşımı geliştirmişlerdir.

Zhou vd (2015) iki boyutlu MR görüntülerinde Otsu ve Ateş böceği algoritmalarını kullanarak bölütleme işlemleri yapmışlardır.

Roy vd (2015) başarılı bir bölütleme tekniği olan MRF (Markov Random Field) tekniğini kullanarak ölü beyin hücrelerinin tespit edilmesi ile ilgili çalışma yapmışlardır.

Prema vd (2016) beyin tümörlerinin bölütlemesi işlemini Otsu algoritmalarını kullanarak tespit etmeye çalışmışlardır. Veri tabanı olarak CT (Computed Tomography) ile oluşturulmuş verileri kullanmışlardır.

Son olarak uzun zamandır kullanılan, ancak son dönemlerde geliştirilerek görüntü bölütlemeye yüksek seviyelerde başarı sağlayan yapay sinir ağları kullanılmıştır. Bu doğrultuda;

Redick vd (1997) beynin gri, beyaz ve diğer bölgelerini birbirinde ayırmak için iki aşamalı bir yöntem geliştirdiler. Yapay sinir ağları ile MR görüntüleri eğiterek bir yöntem geliştirmişlerdir.

Simonyan ve Zisserman (2014) 3x3 boyutlarında filtreli mimari kullanarak CNN temelli bir yöntem geliştirdiler. Bu yöntemle yerleştirme ve sınıflandırmada yüksek seviyelerde başarı sağladılar.

Zhang vd (2015) çoklu MR görüntülerini eğitmek için CNN mimarilerini kullanmışlardır. Girdiler ve çıktılar arasındaki doğrusal olmayan benzerlikleri yok etmeye çalışmışlardır. Bu yöntemle yüksek başarı sağlamışlardır.

Pereira vd (2016) CNN mimarisini kullanarak tam otomatik beyin tümörü tespiti yapan yöntem geliřtirdiler. Bu yöntemde BRATS 2013 veri tabanı kullanılmıřtır. Sonuç olarak yüksek seviyelerde başarı saėlandıėı belirtilmiřtir.

Havaei vd (2017) derin öğrenme yöntemlerini kullanarak tümör tespit etmeye çalışmıřlardır. Veri tabanı olarak BRATS 2013 verilerini kullanmıř ve başarılı sonuçlar elde etmiřlerdir.

Dong vd (2017) derin öğrenme algoritmalarını kullanarak beyin tümörlerinin bölütlemesini gerçekleřtirmiřlerdir. Burada U-Net mimarisi kullanılarak veriler eėitilmiř, mevcut başarı oranları daha da yükseltilmiřtir.

3. MATERYAL ve YÖNTEM

3.1. Beyin Tümörleri

Şen (2016)' na göre beyin hücrelerinin normalden farklı olarak büyümesi sonucunda kötü ve iyi huylu olarak ortaya çıkan yapılara beyin tümörü denir. Beyin tümörleri dünyaya gelen bebekler dahil olmak üzere tüm yaş dönemlerinde görülürler.

Birincil beyin tümörleri içinde en çok görülen yüzde elli oranına ulaşan gliomlardır, sonra yüzde on beş oranında meningiomlar izler Ayrıca yetişkinlerde primer beyin tümörleri çoğunlukla yüzde yetmiş supratentoriyal oluşum gösterir. Çocuklarda infratentoriyel yerleşim yüzde yetmiş oranında görülür. Şiddetli baş ağrısı anamneziyle gelen bir çocukta, tanı olasılıkları arasında, arka çukur tümörü birinci sırada olmalıdır.

3.1.1 Beyin Tümörünün Belirtileri

Beyin de basınç varken normal yapısı kaybolur ve görevlerini tam olarak yapamazlar. Bazı belirtiler görülmeye başlanır. Bunlar;

- Baş ağrısı
- Epilepsi tarzı bayılmalar
- Vücudun bazı bölgelerinde kısmi felçler
- Şiddetli kusmalar
- Bazı fiziksel yeteneklerimizin kaybı
- Kişilik bozuklukları

Şen (2016)'na göre beyin tümörü olan kişilerin yüzde altmışında baş ağrısı vardır. Hastalar ağrının son aylarda ortaya çıktığını ve zamanla şiddetlendiğini ifade eder.

Bulantı kusma belirtileri: baş ağrısı ile beraber özellikle birkaç gün ya da bir haftadır devam etmesi önemlidir. Yalnız baş ağrısı ile kusmanın uzun süreli olması migren ihtimalini akla getirir.

Kol ve bacakta kuvvetsizlik, dengesizlik, bedenin sağ ya da sol yarısında uyuşmalar, ellerde güçsüzlük, uyuşukluk, beceriksizlik şeklinde ortaya çıkar. Yürürken “dengesiz yürüme” ve “dengesizlik” şeklindeki belirtiler bir beyincik tümörünü işaret eder.

Konuşma bozukluğu; Anlama güçlüğü, konuşurken yanlış kelime ifadeleri beyin tümörlerinin ilk belirtisidir.

Sara nöbetleri (epilepsi); hafıza kaybı ile birlikte veya bilinç kaybı olmadan ortaya çıkan istenmeyen kasılmalar, panik atak biçiminde kendini kötü hissetmeler bir epilepsi çeşidi olabilir. Yirmili yaşlardan sonrası ortaya çıkan bu şekildeki nöbetler beyin tümörüne bağlı olduğu düşünülmelidir.

3.1.2 Beyin Tümörünün Çeşitleri

Beyin tümörleri genellikle primer ya da sekonder tipi tümörler olarak olarak sınıflandırılırlar. Genellikle vücutta herhangi bir yer de başlayıp beyine kadar ilerleyen ve beyinde oluşan tümörlerdir.

İyi huylu tümörler: Üreme hızı yavaş olan tümörlerdir. Beyin dokusundan rahatça ayrılabilir ve hepsi ya da bazı kısmı çıkarılabilir. Bu yüzden ameliyat sonrası sonuçları çok iyidir. İyi huylu tümör olsa dahi beyinde önemli bölgelere yerleşmişse sonuçları iyi olmayabilir.

Kötü huylu tümörler: Üremeleri çok hızlı olan tümörlerdir. Çamur kıvamında olduğu için ameliyatta tümü alınamaz. Ameliyattan sonra 5-6 yılda büyüyerek beyine baskı yapabilirler. Bazen bu süre 5-6 aya düşerek hastanın ölümüne neden olur.

İyi huylu ya da kötü huylu tümörlerin tedavileri cerrahidir. Bazen tümör beyin önemli bölümlerine kadar ilerlemişse bu bölgelere dokunulmaz. Bedenin farklı bölgelerinde oluşan tümörlerin beyine yayılmasına metastaz denilir. En çok karşılaşılan akciğer kanserinin beyine yayılmasıdır. Çoğu vakada cerrahi müdahale başarılı olamayacağından hastaya kemoterapi ve ışın tedavisi uygulanır.

3.1.3 Beyin Tümörlerinin Sınıflandırılması

Şen (2016)'na göre beyin tümörleri yerleştikleri bölgeye ve türlerine göre belirtiler gösterirler. Kafa içi basıncının çoğalmasına bağlı olarak çıkan belirti aynı olup bunlar baş ağrısı, bulantı ve kusmadır.

3.1.3.1 Hipofiz adenomları

Şen (2016)'na göre hipofiz adenomları ikiye ayrılır. Bunlar salgı yapanlar ve salgılamayanlar olarak isimlendirilirler. Salgı yapanlar çoğunlukla salgıladıkları hormona bağlı olarak çeşitli sonuçlar ve belirtiler ortaya çıkarırlar. Hormon salgılamayan adenomlar ise uzun süre belirti vermezler. Fakat optik yani görmeyle ilgili sinire baskı yaparak görme bozukluklarına sebep olurlar. Hormon bozuklukları, adet düzensizlikleri veya olmaması, memeden süt gelmesi, aşırı şişmanlama, hızlı boy uzaması, ellerde, ayaklarda ve çenede büyüme hormon bozukluklarının en temel işaretlerindendir.

3.1.3.2 Beyin Zarı Tümörleri

Şen (2016)'na menengiomyomlar çoğunlukla ilerleyerek kafa içi basıncının artmasıyla birlikte kafa ağrısı, bulantı, kusmaya sebep olurlar. Bu tümörler yerleştikleri bölgelere göre belirti verirler. Optik sinir (Görme siniri) yakınına yerleşenler görme bozukluğuna neden olur fakat hareketle ilgili beyin bölgesine yakın yerleşenler felçlere neden olabilirler. Bu yüzden beyin fonksiyonlarındaki bozukluklarda gereken kontroller yapılmalıdır.

3.1.3.3 Metastatik Tümörler

Metastatik tümör çeşitleri bedenin başka bölgelerindeki tümörlerin beyin dokusuna yayılması sebebiyle ortaya çıkarlar. Kafatası içindeki basıncını arttırarak veya yerleştikleri bölgeye göre sinir sistemi hasarı oluşturarak belirti gösterirler. Bu şekildeki sıçramalar tümörlerin ilk belirtisi olabileceği gibi aynı zamanda radyolojik olarak da izlenebilen geniş bir alana yayılmış ödem oluştururlar.

3.1.3.4 Köşe Tümörleri

Bu tümörler beyin dokusunun bir bölgesinde yer alırlar. İşitme siniri tümörü (Akustik nörinom) en çok görülen tümördür. Bunu menegiom (Beyin Zarı Tümörü) ve epidermoid tümörler izler. Beyin tümörlerinin genel belirtilerine ek olarak bölge tümörlerinde işitme ve denge bozuklukları da vardır. Bu tümörler küçük boyutta olduğu zaman fark edildiğinde işitme bölümünü hasardan korunabilir. Tümör çok büyük boyutlara geldiğinde ise işitme korunamadığı gibi aynı zamanda Fasial (Yüz) Siniri de etkilenebilir.

3.1.3.5 Beyin Dokusu Tümörler

Bunun gibi tümörler çoğunlukla kötü huylu ve genel belirtileri olup beyin dokusunun içinde gelişirler. Yerleştikleri bölgelere göre belirtileri vardır. Epilepsi (Sara nöbeti) bazen ilk belirti olarak meydana çıkabilir.

3.1.4 Beyin Tümörleri Tespitinde Kullanılan Yöntemler

- Fiziksel Muayene
- Beyinsel Muayene
- Tomografi (BT)
- MR

- Anjiyografi
- Biyopsi

3.2 MR

Manyetik Rezonans Görüntüleme büyük mıknatıslarla oluşturulan güçlü manyetik alan içerisinde radyo dalgaları kullanılarak belirli anatomik yapılardan diğer yapıları ayırabilmek, sağlıklı ve hastalıklı dokular arasındaki farklılıkları belirlemek ve adlandırmak için kullanılan bir tıbbi tekniktir (Anonim 2009).

3.2.1 Beyin MR nedir?

1. Manyetik Rezonans Spektroskopi (MRS)
2. Difüzyon Ağırlıklı MR
3. Beyin MR
4. Perfüzyon Ağırlıklı MR (PA-MR)
5. Fonksiyonel MR (fMR)
6. MR
7. Kalp ve Damar Emarı (MR)
8. Beden Emarı (MR)
9. Meme Emarı (MR)
10. Kas İskelet Sistemi MR

3.2.2 Beyin MR Çekimi Neler Gösterir?

Beyin tümörleri, felçler, bunama ve multiple skleroz gibi kronik sinir sistemi hastalıklarını belirlemek amacıyla geliştirilmiş hassas bir yöntemdir. Hipofiz bezi, beyin damarları, göz, iç kulak organlarının hastalıklarını anlamlandırmada en hassas yöntem olarak kullanılmaktadır.

- Beyin tümörü tespit edilir.
- Beyin MR görüntüsü ile kemiklerin içi ve daha derin bölgeleri de rahat bir şekilde incelenebilir ve sonucu ile var olan sorunlar ortaya çıkar.
- Kafatasının içinde beyin tümörü, felçler, bunamalar ve sinir sistemi hastalıkları sonuca göre ortaya çıkar.
- Kafatasında yer alan tümör, eklem sorunların ve beyin kanaması tarzındaki sorunlarda meydana çıkar.
- Omurilikte bulunan sorunlarda MR incelemesi ile yapılır. Sonucuyla birlikte var olan hastalıklar meydana çıkar.
- Multiple skleroz, sinir kılıfları incelemeleri de MR ile yapılır. Sonucuyla birlikte var olan hastalıklar meydana çıkar.
- Beyinden çekilen MR uygulaması tümör ve diğer sorunlara göre 10 dakika ve 50 dakika arasında sürer. Rapor sonucuna göre hastalık belirlenir ve tedavi süreci planlanır.
- Tümör yapıları ile tümör çeşitleri MR işlemleri ile ayrıntılı bir şekilde incelenir.
- Kan akışı en küçük ayrıntısına kadar görüntülenir.
- Emboli ve tümör sorunlarının tamamı MR uygulamasıyla kısa sürede incelenir.

3.3 Derin Öğrenme Nedir?

Derin Öğrenme, yapay sinir ağları denilen beynin yapısı ve fonksiyonundan esinlenen algoritmalarla ilgili makine öğrenmesinin bir alt alanıdır (Anonim 2017).

Derin öğrenme, sürücüsü olmayan arabaların arkasında duran bir işareti tanımak veya bir yaya parkurundan bir yayayı fark etmek için kullanılan temel bir teknolojidir. Telefonlar, tabletler, TV'ler ve ahizesiz konuşmacılar gibi tüketici aygıtlarında ses kontrolü için anahtar görevi üstlenmektedir. Bu yüzden derin öğrenme son zamanlarda çok dikkat çekmektedir. Daha önce imkânı olmayan sonuçlar elde edilmektedir.

Derin öğrenmede, bir bilgisayar modeli, sınıflandırma görevlerini direk olarak görüntülerden, metinden veya sestten gerçekleştirmeyi öğrenir. Derin öğrenme modelleri, bazen insan düzeyinde performansı aşan, en son teknoloji doğruluğunu sağlayabilir.

Modeller, birden fazla katmanı içeren etiketli veri ve sinir ağı mimarileri grubunu kullanarak eğitilir.

3.3.1 Derin Öğrenme Neden Önemlidir?

Derin öğrenme, her zaman daha yüksek seviyelerde tanıma doğruluğuna ulaşır. Bu, tüketici elektroniğinin kullanıcı isteklerini karşılamasına yardımcı olur ve sürücüsüz otomobiller gibi güvenlik açısından kritik uygulamalar için çok önemlidir. Derin öğrenmede son gelişmeler, görüntülerde nesnelerin sınıflandırılması gibi bazı görevlerde Derin öğrenmenin insanların seviyesine göre daha iyi olduğu bir noktaya gelmiştir.

Derin öğrenme ilk olarak 1980'lerde teori olarak kalmışken, son zamanlarda kullanışlı hale gelmesinin iki temel nedeni vardır:

- Derin öğrenme algoritmalarında, büyük miktarda **etiketlenmiş veriye** ihtiyaç vardır. Örneğin, sürücüsüz araç gelişimi milyonlarca görüntü ve binlerce saat video gerekir (Anonim 2017).
- Derin öğrenme, önemli **bilgisayar gücü** gerekir. Yüksek performanslı GPU' lar, derin öğrenme için etkili paralel bir mimarileri vardır. Kümeler veya bulut bilgi işlem ile birleştirildiğinde, geliştirme takımları, derin bir öğrenme ağının eğitim süresini günlere veya birkaç saat veya daha kısa süre azaltabilir (Anonim 2017).

3.3.2 Derin Öğrenme Nasıl Çalışır?

Derin öğrenme yöntemlerinde sinir ağı mimarilerini kullandığından derin öğrenme modellerine çoğunlukla Derin Sinir Ağları da denir. "Derin" terimi çoğunlukla sinir ağındaki gizli tabakaların sayısını gösterir. Geleneksel sinir ağları sadece 2-3 gizli katmanı içerirken, derin ağlar 150' ye kadar olabilir.

Derin öğrenme modelleri, manuel öznitelik çıkarımı yapmadan verileri doğrudan özelliklerini öğrenen geniş etiketli veri dizileri ve sinir ağı mimarileri kullanarak eğitilir.

Derin sinir ağlarının en popüler çeşitlerinden biri konvolüsyonel sinir ağları (CNN veya ConvNet) olarak bilinir.

3.4 Evrişimli Sinir Ağları (Cnns/Convnets)

Evrişimli Sinir Ağları, öğrenilebilir ağırlık ve yanlılığa sahip nöronlardan oluşan sıradan Sinir Ağlarına çok benzemektedir. Her nöron bazı girdileri alıp bir nokta ürünü yaparak isteğe bağlı olarak doğrusal olmayan bir şekilde ilerler. Tüm ağ tek bir ayırt edilebilir işlevi ifade ederek son katman (tamamen bağlı) üzerinde bir kayıp fonksiyonuna (ör. SVM / Softmax) sahip olup düzenli Nöral Ağları öğrenmek için geliştirdiğimiz tüm ipuçları ve püf noktalarını ifade eder.

ConvNet mimarileri girdilerin ve görüntülerin olduğu bir mimariye belirli özellikleri kodlayabilmemizi sağlayan açık bir varsayımdır. Bu varsayım daha sonra yapılacak işlevleri daha verimli hale getirerek ağıdaki parametrelerin miktarını büyük ölçüde azaltır (Recognition 2017).

3.4.1 Mimariye Genel Bakış


Nöral Network bir girdi (tek bir vektör) alıp bir dizi gizli katmana dönüştürür. Her bir gizli katman, her nöronun bir önceki katmandaki tüm nöronlara tamamen bağlı olduğu, tek bir katmandaki nöronların tamamen bağımsız olarak işlev gördüğü ve herhangi bir bağlantıyı paylaşmadığı bir dizi nörondan oluşur. Sınıflandırma ayarlarında sınıf puanlarını temsil eden son bağlanan katmana “çıktı katmanı” denir.

Normal Sinir Ağları, tam görüntülere iyi ölçeklenmez. Bazı görüntüler sadece 32x32x3 (32 geniş, 32 yüksek, 3 renk kanalı) boyutundadır. Bu nedenle düzenli bir Sinir Ağı'nın ilk

gizli katmanındaki tek bir tam bağlı nöron $32 * 32 * 3 = 3072$ ağırlığa sahip olacaktır. Bu miktar yönetilebilir görünmesine rağmen Tam Bağlı yapı, daha büyük görüntülere ölçeklendirilmez. Örneğin, $200 \times 200 \times 3$ boyutlarında istenen bir görüntü, $200 * 200 * 3 = 120,000$ ağırlığa sahip nöronların oluşmasını sağlar. Bu durum parametrelerin hızlı toplanabilmesini sağlasa da parametrelerin fazla olması aşırı işlem yapılmasına neden olur.

3.4.2 Üç boyutlu Nöronlar

Evrişimli Sinir Ağları, girdinin imgelerden oluşması ve sınıflandırılabilir olması özelliğini kullanır. Normal bir Sinir Ağından farklı olarak, bir ConvNet' in katmanları 3 boyutta düzenlenmiş nöronlara sahiptir. Bunlar genişlik, yükseklik ve derinliktir. (Buradaki derinlik terimi, bir ağdaki toplam katman sayısını ifade eden tam bir Nöral Ağın derinliği değil, bir aktivasyon hacminin üçüncü boyutuna karşılık gelir.) Bir katmandaki nöronlar, tüm nöronların tam olarak bağlanması yerine, yalnızca tabakanın küçük bir bölgesine bağlanacaktır. ConvNet mimarisinin sonunda tam görüntü, derinlik boyutu boyunca düzenlenmiş tek bir görüntü vektörüne indirgenmelidir. İşte bir görselleştirme:

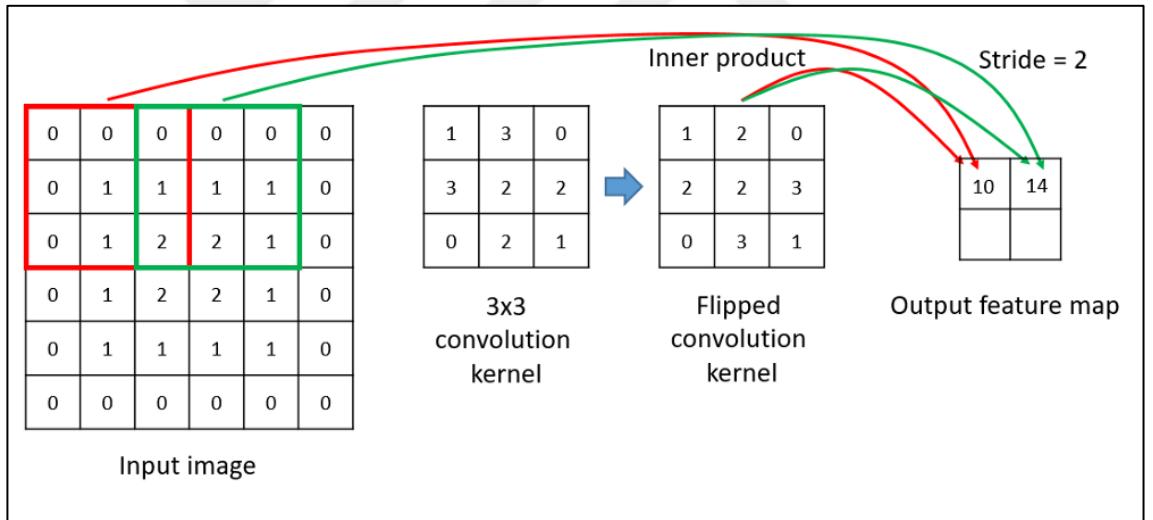


Şekil 3. 1. Düzenli 3 katmanlı bir Sinir Ağı. Sağ: Bir ConvNet, nöronlarını katmanlardan birinde görselleştirildiği gibi üç boyutta (genişlik, yükseklik, derinlik) düzenler.

3.4.3 İki Boyutlu Evrişim (2D Convölasyon)


İki boyutlu veriye filtre oluşturmak için x ve y eksenine göre simetri alınır. Simetrisi alındıktan sonra matris içerisindeki veriler eleman eleman çarpılarak tüm değerler toplanıp çıkış matrisinin ilgili birimi gibi depolanır.. Yaptığımız bu işleme Çapraz Korelasyon denir. Giriş verisi tek kanallı olduğunda işlem herhangi bir zorluk olmamaktadır.

Modelimiz her konvolüsyon aşaması sonucunda değişik ağırlıklara sahip fonksiyonlar ile hesaplanır. Katman sayısı fazlaştıkça filtrelerde oluşan öznelilikler görüntünün derinlik kısmını simgelemektedir.



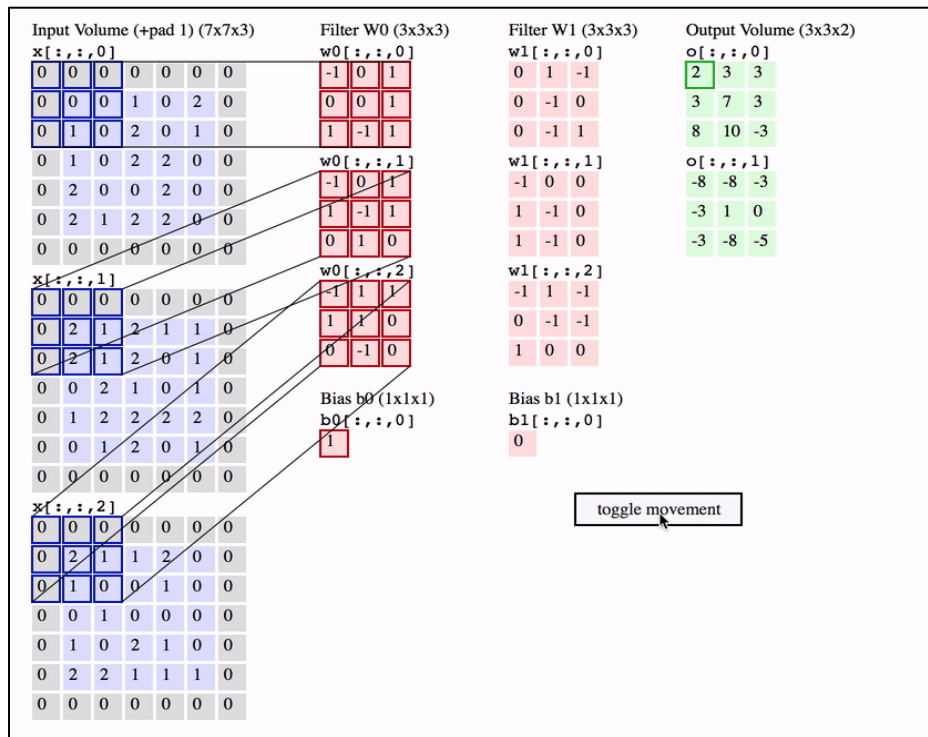
Şekil 3. 2. İki boyutlu evrişim işlemi gösterimi

Eğer görüntümüz renkli ise, Kırmızı-Yeşil-Mavi (RGB) 3 kanaldan konvolüsyon işlemi olur. Çıkış sinyalinin kanal adeti uygulanan filtre kanalı veya adeti ile aynı olacak şekilde hesaplanır.



Şekil 3. 3. Yatay ve Dikey Filtreleme İşlemi

Bu hesaplama işlemini ağdaki bir katman olarak düşünülebilir. İlk görüntü ve filtre, devamlı geri yayılımla değişen ağırlıklar matrisidir. Aktivasyon fonksiyonunu uygulanan çıkış matrisine en son skaler bir b (bias) değeri eklenir.

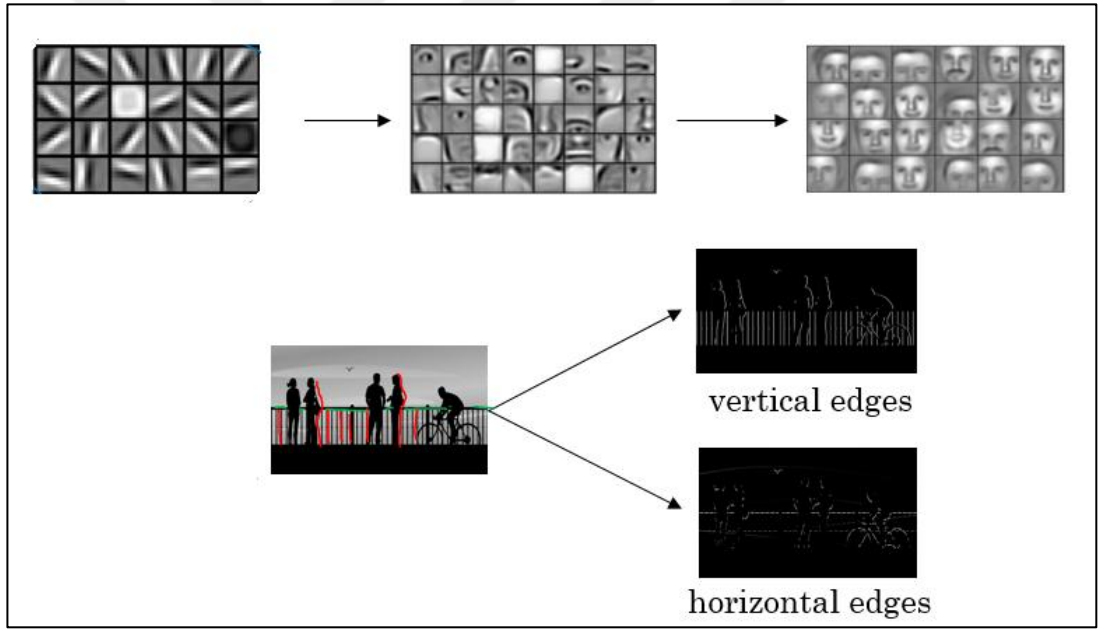


Şekil 3. 4. Convolutional Neural Networks (Recognition 2017)

Ağımızın konvolüsyon katmanı sonucunda değişik ağırlıklara sahip filtreler oluşturulur ve katman sayısı ileri yönde değiştikçe filtrelerde oluşan öznitelikler görüntünün derinlik kısmını oluşturmaktadır.

3.4.4 Kenar Bulma

Resimlerde elde edilen sonuçlar içinde en çok ihtiyaç duyulanlarından biri kenar bilgileridir. Bu bilgileri elde etmek için dikey ve yatay filtreler ayrı ayrı kullanılır. Çıkış bilgileri görüntünün kenar bilgilerini gösterir.




Şekil 3. 5. Yatay ve Dikey Kenar Bulma (Anonim 2016)

Kenar bulma fonksiyonları karanlıktan aydınlığa, aydınlıktan karanlığa geçişler ayrı ayrı birer öznitelik olarak değerlendirilir ve hesaplanır. Genellikle kenarlar, konvolüsyon ağının birinci katmanlarında hesaplanmaktadır. Bu hesaplamaların sonucunda giriş boyutu ve çıkış boyutu arasında değişimler meydana gelir (Kızrak.A 2018).

3.4.5 Dolgulama (Padding)

Konvolüsyon sonucunda giriş işareti ile çıkış işareti arasındaki boyutlarını ayarlamak için pikseller kullanılır.



Şekil 3. 6. Dolgulama

Bu işleme piksel ekleme işlemi (padding) denir. Giriş matrisi $n \times n$, filtre (ağırlık) matrisi $(f \times f)$ olduğu durumda çıkış matrisinin giriş ile aynı boyutlu olması isteniyorsa;

$$(n + 2p - f + 1) \times (n + 2p - f + 1) \quad (\text{Denklem 3.1})$$

formülü uygulanır.

Burada ‘p’ ile gösterilen değer giriş matrisine eklenen piksel boyutudur. Bunu belirlemek için

$$p = (f - 1)/2 \quad (\text{Denklem 3.2})$$

denkleminde faydalanılır (Kızrak.A 2018).

3.4.6 Kaydırma Adımı (Stride)

Çıkış boyutunu etkileyen parametrelerden biri de Kaydırma Adımı (Stride)'dir. Görüntüde istenilen adım kadar kaydırma yapar. Aşağıdaki formülde yer alır.


$n \times n$ görüntü, $f \times f$ filtre, p dolgulama, s adım sayısı

$$\left\lceil \frac{n+2p-f}{s} + 1 \right\rceil \times \left\lceil \frac{n+2p-f}{s} + 1 \right\rceil \quad (\text{Denklem 3.3})$$

Eğer $p=1$ iken, $s=2$ seçildiğinde çıkış matrisinin boyutu

$$(((n + 2p - f)/s) + 1) \times (((n + 2p - f)/s) + 1) \quad (\text{Denklem 3.4})$$

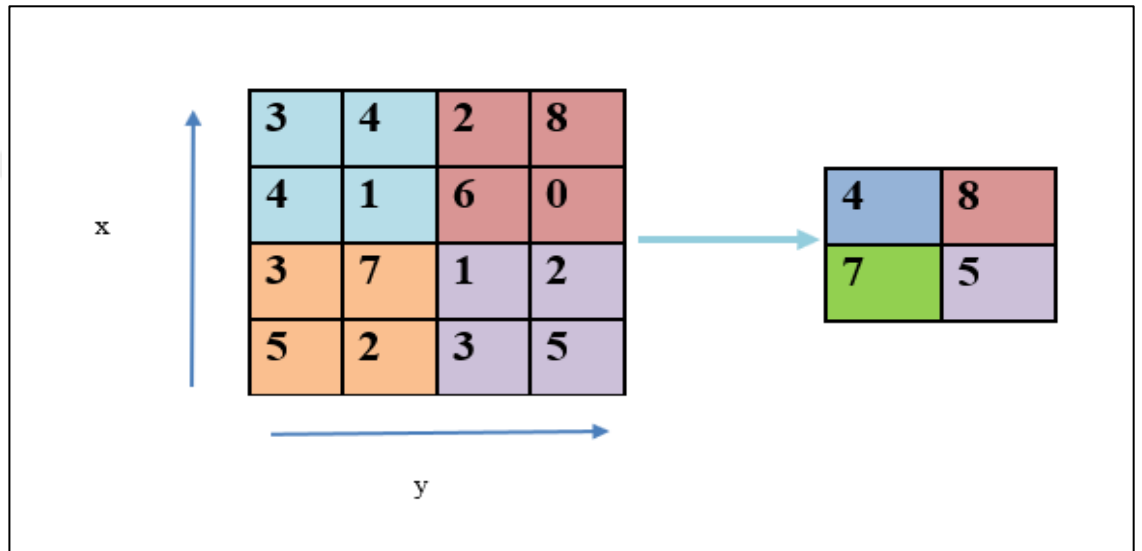
$n=5$ ve $f=3$ değerleri için hesaplanırsa çıkış değerleri $(3) \times (3)$ olur. Piksel ekleme işleminde eklenen pikseller aşağıdaki örnekte olduğu gibi sıfırlardan oluşabilir. Farklı uygulanma şekillerinden biri ise bitişiğindeki piksel değerinin aktarılmasıdır.



Şekil 3. 7. Kaydırma Adımı Gösterimi

3.4.7 Ortaklama (Pooling)

Ağın bu seviyesinde genellikle maksimum ortaklama yöntemi kullanılır. Yükseklik ve genişlik bilgisi azaltmak için giriş matrisinin kanal sayısı sabit tutulabilir. Bu seviyede öğrenilen bir parametre olmayıp hesaplamayı kolaylaştırmak için kullanılan bir adımdır.



Şekil 3. 8. Max Pooling Gösterimi


Belirlenen ortaklama boyutu içindeki en büyük değer alınır. Yukarıdaki 2x2 max-pooling işleminde 2 adım kaydırılarak piksellerin en büyüğü çıkışa aktarılır. Böylece boyutu 4 kat küçültülmüş bir veri elde edilmiş olur.

3.5 Ağ Modelleri

Geçmişten günümüze kadar birçok ağ modeli geliştirilmiştir. Bunlardan bazıları LeNet-5, AlexNet, VGG16 ve ResNet ve Network in Network, GoogLeNet modelidir.

3.5.1 LeNet-5

Bu alanda başarılı sonuç veren ilk konvolüsyonlu nöral network modelidir. Yann LeCun ve arkadaşları tarafından adres numaraları, banka evrakları üstündeki rakamların belirlenmesi için geliştirilmiştir. Modelimiz de sonradan geliştirilecek diğer modellerden farklı olarak boyut azalma adımlarında maksimum havuzlama yerine ortalama havuzlama işlemi yapılmaktadır (Kızrak.A 2018).



Şekil 3. 9. LeNet-5 Modeli (Kızrak.A 2018)


Tam Bağlantı katmanının da oluşan parametre sayısı $5 \times 5 \times 16 = 400$ ve y çıkışında 0–9 arasındaki rakamları sınıflandırdığı için 10 sınıflı softmax bulunmaktadır. Bu ağ modelinde 60 bin parametre hesaplanmaktadır. Ağ boyunca matrisin yükseklik ve genişlik bilgisi azalırken derinlik (kanal sayısı) değeri artmaktadır.

3.5.2 AlexNet Modeli

2012 yıllarında konvolüsyon nöral network modellerini ve derin öğrenmenin tekrar gündeme gelmesini sağlayan ilk modeldir. Birbirini takip eden konvolüsyon ve havuzlama katmanları bulunmasından dolayı LeNet modeline benzemektedir. Aktivasyon fonksiyonu olarak ReLU (Rectified Linear Unit), havuzlama katmanlarında da maksimum havuzlama kullanılmaktadır.

Büyüklik ve derinlik oranları yüksek olan bu modeli paralel iki GPU (Grafik İşlem Birimi) üzerinde iki elemanlı bir modeldir. Ortalama altmış milyon parametre hesaplanmaktadır. ImageNet yarışmasında sınıflandırma doğruluk oranını %74,3'ten

%83,6'ya ani bir yükselme sağlayarak görüntü sınıflandırma probleminde bir kırılma noktasıdır (Kızrak.A 2018)..

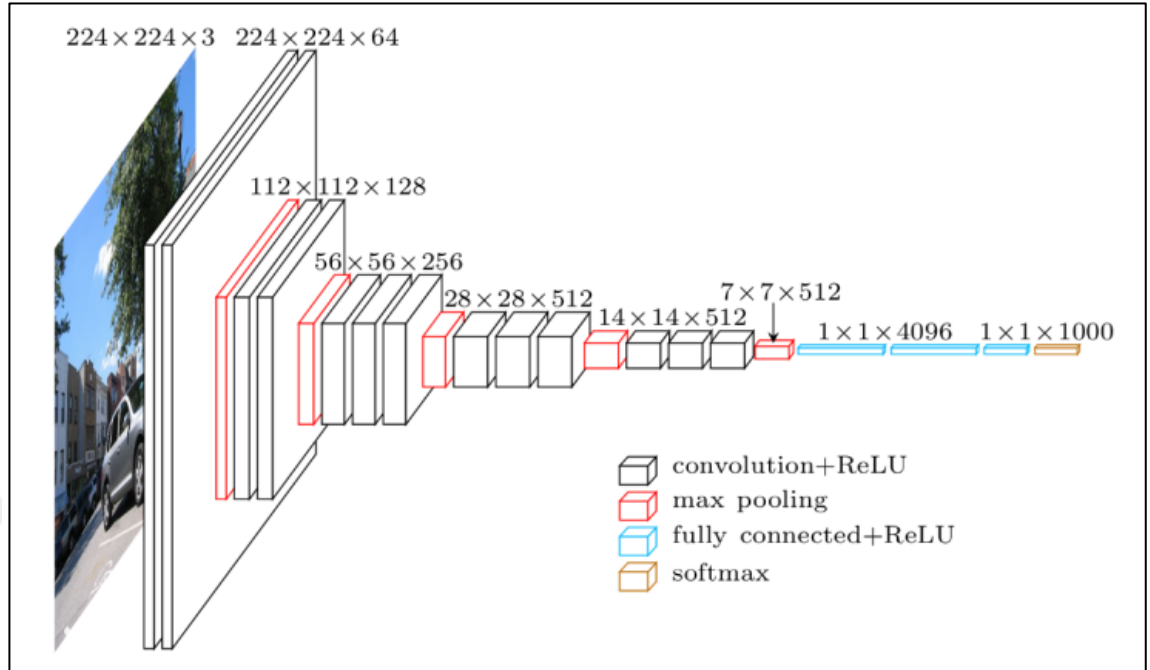


Şekil 3. 10. AlexNet Modeli (Anonim 2018)

3.5.3 VGG-16

Bu ağ modeli olup önceki modellerden farklı ikili ya da üçlü evrişim katmalarının kullanılmasıdır. Tam bağlı katmanında görüntü $7 \times 7 \times 512 = 4096$ nöronlu bir öznitelik vektörüne dönüştürülür. İki tane tam bağlı katmanın çıkışında 1000 sınıflı softmax başarımı hesaplanır. 138 milyon parametre hesabı yapılabilmektedir. Diğer modellerde olduğu gibi girişten çıkışa doğru matrislerin yükseklik ve genişlik boyutları azalırken derinlik değeri (kanal sayısı) artmaktadır (Simonyan and Zisserman 2014).

Konvolüsyon katmanı sonucunda değişik ağırlıklara sahip filtreler belirlenir ve katman sayısı çoğaldıkça belirlenen filtrelerde oluşan öznitelikler görüntünün derinlik kısmını simgelemektedir.



Şekil 3. 11. VGG-16 Modeli (Anonim 2018)

3.5.4 ResNet

Ağ modelinin gerçek anlamda derinleşmeye başladığı kendinden önceki modellerden farklı bir mantığı barındıran ResNet; artık değerlerin (residual value) sonraki katmanlara besleyen blokların (residual block) modele eklenmesiyle oluşmaktadır.

Teorik olarak, modelde katman sayısı arttıkça başarımın artacağı düşünülür. Ancak gerçekte böyle olmadığı deneyimlenmiştir. Buradan hareketle ResNet modeli oluşturulmuştur. Böylece $w[l+2]=0$ olduğu durumda yeni teoriye göre $a[l+2]=b[l+2]$ olur. Bu (vanishing gradient) istenmeyen bir durumdur (Kızrak.A 2018).


Ancak artık değer (residual) beslemesi yeni çıkış eşitliğini iki önceki katmandan gelen $a[l]$ değeri o an ki ağırlık 0 olsa bile öğrenme hatasını optimize eder. Daha hızlı eğitilir (He, Zhang et al. 2016).

3.5.5 Ağ İçinde Ağ

2013 yılında Min Lin ve arkadaşlarının “Network in Network” makalesi ile modellerdeki hesaplama karmaşıklığına yeni bir çözüm önermiştir. Google bu yöntemi kullanmış ve başarıya ulaşmıştır. Hesaplama esneklik sağlanmış ve başarıyı artırmak için varyasyonlu modellerin tasarlanmasına olanak tanınmıştır (Kızrak.A 2018).

3.5.6 Inception Ağlar (GoogLeNet)

Karmaşık hesapların büyüklüğüne, çözüm hız ve başarı getirmektedir.




Şekil 3. 12. GoogleNet Modeli (Anonim 2018)

GoogleNet ağ modeli modüllerden oluşur ve her bir modül, farklı boyutlu konvolüsyon ve maksimum havuzlama işlemlerinden oluşur. Yukarıdaki şekilde üç farklı konvolüsyon ve bir maksimum havuzlama işlemi sonucunda 28x28x256 boyutlu bir tensör elde edilmiştir. Şimdi bu işlemlerin nasıl yapıldığına bakalım:

Sadece bu işlem adımı için $(28 \times 28 \times 32) \times (5 \times 5 \times 192) = 120$ milyon parametre hesaplanması gerekmektedir ve diğer konvolüsyon ve havuzlama katmanlarını da aynı şekilde hesaplanması gerekmektedir.

(Szegedy, Liu et al. 2015) ‘Ağ içinde Ağ’ makalesine atıf yaparak her konvolüsyon katmanından önce 1x1 konvolüsyon katmanı kullanılmasını önermiştir. Böylelikle işlem yükü daha da az hale gelmiş olur. Bu şartlarda; 1x1 konvolüsyon katmanında: $(28 \times 28 \times 16) \times (1 \times 1 \times 192) = 2,4$ milyon parametre ve 5x5 konvolüsyon katmanında: $(28 \times 28 \times 32) \times (5 \times 5 \times 16) = 10$ milyon parametre kullanılarak sonuçta 12.4 milyon parametre belirlenmektedir. İlk duruma göre yaklaşık 10 kat daha az parametre kullanılmış olur. Bu işlemi de ‘bottleneck’ (darboğaz) olarak adlandırılmışlardır.

Her bir kısmına ‘inception’ denilmektedir ve toplam dokuz inception bloğundan oluşan modele GoogLeNet adı verilmektedir.



Şekil 3. 13. GoogLeNet Genel Gösterimi

3.5.7 Transfer Öğrenme

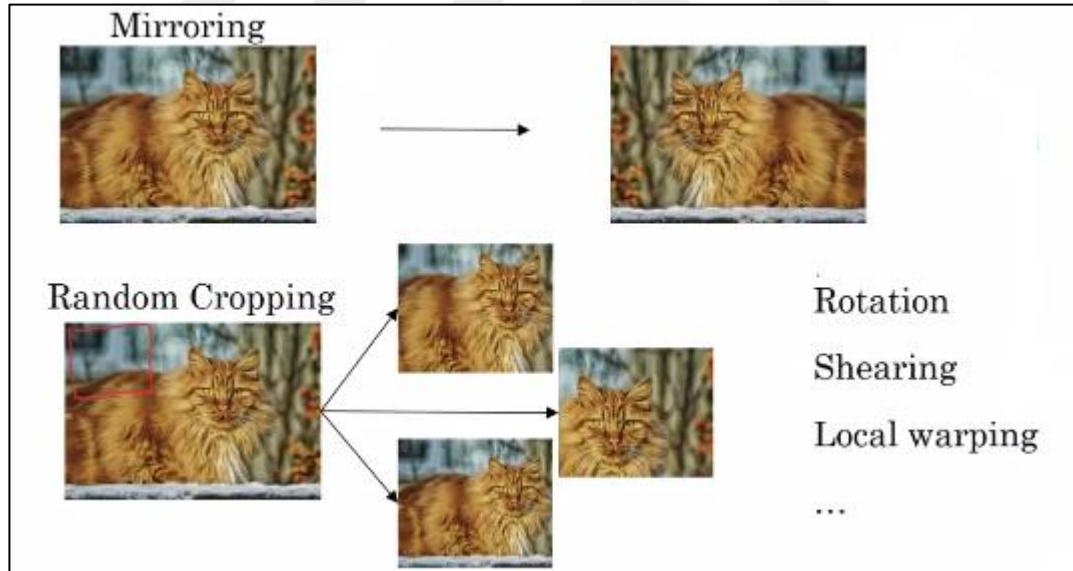
Bir kısım modellerin eğitilmesi, model karmaşıklığı ya da veri setinin büyüklüğü nedeniyle standart bilgisayar işlemcilerinde gerçekleştirmek çok zor olabilir. Bu nedenle GPU’lara ihtiyaç vardır. Çok uzun zaman alan eğitimler sonucunda elde edilmiş modeller farklı problemlerin çözümü içinde çeşitli şekillerde kullanılabilir. Bu işleme ‘Transfer Öğrenme’ denir. Mesela ImageNet gibi 15 milyon farklı görüntüden oluşan veri setiyle eğitilmiş bir model varsa elinizdeki veri setimizin görüntü sayısının az olması başarı oranımızı azaltmaz. Bu nedenle çok daha başarılı sonuçlar üretmiş oluruz. Transfer öğrenme aşağıdaki şekillerde uygulanabilir.

- Tüm modeli durdurulup softmax sonucunu kendi probleminizin sınıf sayısına göre ayarlayarak,
- Modelimizin bazı katmanlarını sabit tutup son katmanlarına farklı değerler kullanarak modeli düzenlemek,

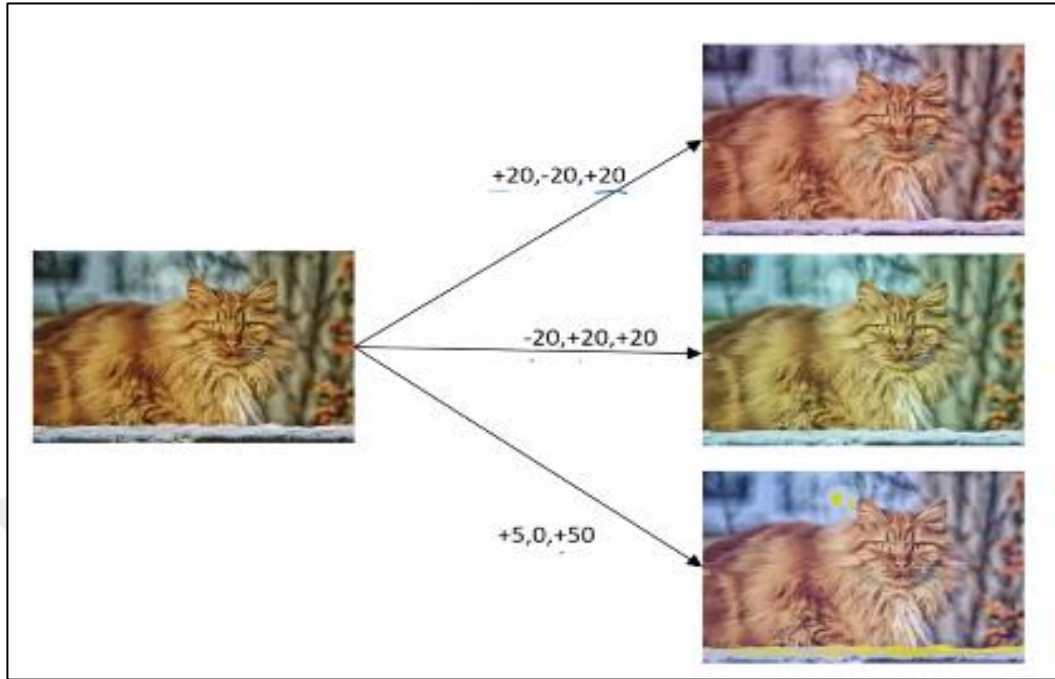
Transfer öğrenme, yapay zekâ çalışmalarında çoğu sorunun hızlı bir biçimde çözümlememizi sağlamaktadır.

3.5.8 Veri Artırma (Data Augmentation)

Veri setlerinin küçük olması ve az sayıda veri içermesi durumunda başarıyı yükseltmek amacıyla verileri çeşitli değişikliklere uğratarak (bozulma etkilerine maruz bırakılarak) artırılmasına veri artırma denir.



Şekil 3. 14. Veri Büyütme Gösterimi



Şekil 3. 15. Veri Büyütme Gösterimi-2

- Görüntünün farklı eksenlere göre simetriklerinin alınması,
- Farklı bir örnek parçasının kesilip alınması,
- Eksenlerinin değiştirilmesi,
- Renk oranlarının değiştirilmesi,

gibi birçok farklı şekilde veri büyütme işlemi yapılmaktadır (Kızrak.A 2018).

3.6 Derin Öğrenme Uygulamalarında Kullanılan Hiperparametreler

3.6.1 Veri Seti


Derin öğrenme uygulamalarında veri setinin önemi çok fazladır. Özellikle veri setimizin büyüklüğü ve çeşitliliği ağıımız için önemli faktörlerden biridir. Veri setinin büyüklüğünün fazla olması öğrenme oranını da artıracaktır. Veri setinin büyüklüğü öğrenme zamanını ve öğrenme sonucunda oluşturulan modelin büyüklüğünü de aynı oranda arttırmaktadır. Eğitim sıklığının az olması ve depolama alanın yeterli olması

durumunda bu sorun pek önemsenmez. Fakat sıklıkla eğitilmesi gereken veya geniş depolama alanı isteyen ortamlar da çalışılması durumunda veri setinin büyüklüğü değerlendirmeye alınmalıdır. Veri setinin çeşitliliği de veri setinin büyüklüğü gibi modelin başarısını artırmaktadır (Çarkacı.N 2018).

Ancak veri setini sürekli artırma başarıyı en yüksek noktaya çıkarmasını beklemekte yanlış olacaktır. Belirli bir noktadan sonra veri setinin büyüklüğü modelimizin başarısını artırmayacaktır. Bu yüzden veri seti büyütülürken bu noktaya dikkat etmemiz gerekir.

3.6.2 “Mini-Batch” Boyutu

Öğrenmenin her iterasyonunda geriye yayılım (“backpropagation”) işlemi, zaman ve hafıza açısından maliyetlidir. Çünkü ağ üzerinde gradyan (“gradient descent”) hesaplaması yapılmaktadır. Böylelikle ağırlık değerleri bu şekilde güncellenmektedir. Buna benzer hesaplama işleminde veri sayısı fazla olması hesaplama işleminin uzun sürmesine neden olmaktadır. Bu sorunun üstesinden gelmek için öncelikle veri setini küçük gruplara ayırıp ve öğrenme işlemini seçilen bu küçük gruplar üzerinde yapılmalıdır. Bu şekilde birden fazla girdinin parçalar halinde işlenmesi “mini-batch” olarak adlandırılmaktadır. Model tasarlanırken mini-batch parametresi olarak belirlenen değer, modelin aynı anda kaç veriyi işleyeceği anlamına gelmektedir (Çarkacı.N 2018).



Şekil 3. 16. Mini-batch sonrası hata değeri değişimi

Mini-batch uyguladığımızda Şekil 2 16'daki grafikte de görüldüğü gibi hata değerinde farklılaşmalar yaşanmıştır. Bunun nedeni her denemede farklı veriler işlendiği için bazı

denemelerde veriler için belirlenen parametreler tamamen uygun iken bazılarında uygun olmayabilir. Bununla birlikte denemeler arttıkça bu değişimler azalacaktır. Mini-batch durumunda meydana gelen bu gürültü değerini düşürmenin diğer bir yolu da küçük öğrenim değeri belirlemektir (Çarkacı.N 2018).

Mini-batch değeri genellikle bir ile eğitim ağındaki eleman sayısı arasında bir değer olarak belirlenir. Mini-batch değerini alabileceği en küçük değeri belirlediğimizde sadece tek bir veri üzerinden işlem yapılmış olur (SGD).

Mini-batch en yüksek değeri seçildiğinde, eğitim ağıdaki bütün verilerin eğitim ağına katılmasıyla yapılan işlem “batch gradient descent”le aynı olacak ve modelimiz daha az gürültü öğrenecektir. Bütün veriler aynı anda işleneceği için öğrenme çok zaman alacaktır (Ruder.S 2017).

En uygun Mini-batch değerinin bir ile eğitim ağındaki tüm verilerin sayısı arasında ortalamaya yakın bir değer seçilmesi gerekmektedir. Mini-batch boyutunun belirlenirken dikkat edilmesi gereken noktalar;

- Batch size’ ın büyük olması durumunda linerizasyon azaltmaktadır.
- Belirlenen batch değeri ikinin katları olarak GPU belleğine sığacak şekilde seçilmelidir. Aksi halde başarımda ani düşüşler yaşanabilir.
- Eğitim setindeki eleman sayısı az ise (yani 2000’den az ise) eğitim setindeki tüm elemanlar aynı anda kullanılarak batch gradyan hesaplaması yapılabilir.
- Batch değerindeki küçük değişiklikler, evrimsel sinir ağlarının (Convolutional Neural Networks) başarısında büyük değişikliklere yol açabilir.
- Batch değerinin küçük olması modelinizin başarı oranını artırabilir.
- Veri setimizi bölümlere ayırmadan veri seti birbirleriyle karıştırılmalıdır (shuffle).

3.6.3 Öğrenme Hızı ve Momentum Katsayısı

Derin öğrenmede parametrelerin yenilenerek belirlenmesi geriye yayılım (“backpropagation”) fonksiyonuyla belirlenmektedir. Geriye yayılım işleminde bu güncelleme işi “chain rule” olarak isimlendirilir. Geriye doğru türev olarak farkın bulunması ve bulunan fark değerinin “learning rate” parametresiyle çarpılması, çıkan sonucun ağırlık değerlerinden çıkarılarak yeni ağırlık değerinin hesaplanmasıyla yapılmaktadır. Bu işlem esnasında kullanılan “learning rate” parametresi sabit değer olarak belirlenebilir, ya da aşama aşama artan bir değer olarak da belirlenebilir, momentum değerine bağlı olarak belirlenebilir ya da adaptif algoritmalar tarafından öğrenme esnasında öğrenilebilir (Çarkacı.N 2018).

SGD gibi fazla salınım oluşturan ve gürültü üreten yöntemler bazı teknik işlemlerle normalize edilerek dalgalanmaları değerleri düşürülmektedir. Bu işlemi momentum beta katsayıları ile normalize edilmektedir. Bu yöntem ile üretilen yeni değeri aynen almak yerine, beta katsayısı ile güncellenen bir önceki değeri de hesaplama işleminde kullanarak yeni değeri oluşturmaktır. Böylece gürültü ve grafikteki salınımlar azaltılarak daha hızlı bir yöntem oluşturulur.

Öğrenme hızı ve momentum ile ilgili bazı özellikler aşağıdaki gibidir;

- Öğrenme hızını yukarıda tutmak veriden çok etkilenmeyi sağlar.
- Öğrenme hızının yüksek olması salınıma, küçük olması da öğrenimin uzun sürmesine neden olacaktır.
- Öğrenme hızı için en uygun çözüm, başlangıçta öğrenme hızını yüksek tutmak ve gittikçe azaltmaktır.
- Öğrenme hızı değeri genelde 0,01 olarak kullanılmakta belli bir epoch’ dan sonra 0.001’e düşürülmektedir.
- SGD momentum ile kullanıldığında hızı artırmakta ve salınımları azaltmaktadır. Genellikle momentum beta katsayısı 0.9’ olarak kullanılır. Genellikle kullanılan aralığı ise 0.8 ile 0.99’dur.

3.6.4 Optimizasyon Değerlerinin Belirlenmesi

Modelimizin optimum değeri bulmak için bazı optimizasyon yöntemleri kullanılarak uygun parametreler belirlenir.

Stochastic gradient descent,


Adagrad,

Adadelata,

Adam,

Adamax

Bu algoritmalar arasında başarı ve hız açısından farklıdır.



Şekil 3. 17. Bazı optimizasyon algoritmalarının çalışma zamanı grafiği (Ruder.S 2017)

İki çeşit gradient hesaplama yöntemi vardır. Bunlar sayısal (numeric) ve analitik (analytic) olarak adlandırılır. Sayısal gradient yöntemi kolay uygulanır, yaklaşık sonuç verir ama yavaş çalışır. Analitik gradient ise hızlı çalışır, tam sonuç verir ama hataya eğilimlidir. Pratikte analitik gradient ile hesaplama yapılır ve sonuçlar sayısal gradient ile kontrol edilir.

Derin öğrenme ağlarında genellikle varsayılan olarak kullanılan optimizasyon algoritması Stochastic Gradient Descent (SGD). Stochastic Gradient Descent diğer yöntemlere göre daha yavaş çalışmaktadır. Stochastic Gradient Descent (SGD) özellikle resim tanıma problemlerinde çok kötü sonuçlar verebilmektedir. Adaptive algoritmalar dinamiktir ve öğrenme hızını (learning rate) kendisi öğrenmektedir (Çarkacı.N 2018).

AdaGrad NLP ve görüntü tanıma gibi veriler için daha elverişlidir. Çünkü seyrek parametreler için genellikle büyük güncellemeler yaparken sık parametreler için daha küçük güncellemeler yapar.

AdaGrad'da parametrelerin kendisini ait öğrenme hızları vardır. Algoritma özelliklerine göre öğrenme oranı giderek düşmektedir. Bu nedenle zamanın bir noktasında sistem öğrenmeyi bırakır. AdaGrad'ın en büyük dezavantajı budur.

AdaDelta, bu sorununu çözerek bu hızlı düşüşü önler.

Adam (adaptif momentum) AdaDelta'ya ile hemen hemen aynı özelliklere sahiptir ama AdaDelta'dan farklı olarak parametrelerin her birinin öğrenme oranları ile birlikte momentum değişikliklerini de önbellekte (cache) saklar (RMSprop ve momentumu birleştirir)(Dong, Yang et al. 2017).

3.6.5 Epoch (Eğitim tur) Sayısı

Model eğitilirken veriler belirli sayıda ve bölüm halinde eğitime katılırlar. Birinci parça eğitilip ve modelin başarısı test edildikten sonra başarıya göre geriye yayılım ("backpropagation") ile ağırlıklar tekrar hesaplanır. Yeni eğitim sınıfı ile model tekrar eğitilip ağırlıklar tekrar hesaplanır. Bu işlemler her eğitim safhasında tekrarlanıp model için en uygun ağırlık değerleri hesaplanır. Bu işlemlerdeki her eğitim adımına "epoch" denilmektedir.

Genellikle ilk epoch' lar da başarımlar düşük olur çünkü derin öğrenmede problemi çözecek en uygun ağırlık değerleri adım adım hesaplanır. Epoch sayısını artırdığımızda başarımlar da artacaktır. Fakat belirli bir adımdan sonra modelimizin öğrenme durumu oldukça azalacaktır. Bu yüzden Epoch sayısını sürekli artırmak bazı algoritmalar için mantıklı olmayacaktır.

Genellikle modeli eğitmek günlerce aylarca sürebilir. Derin öğrenmede bu durum normaldir. Hiperparametreler kullanılarak bu süre kısaltılabilir.

3.6.6 Başlangıçtaki Ağırlık Değerlerinin Saptanması

Başlangıçta ağırlık değerlerinin (W) tümü 0, standart sapması 0.5 ve 0.5 ile 0.9 arasında bir değer veya önceki bir modelin ağırlık değerleri kullanılarak belirlenebilir. Başka ağırlık belirleme yöntemleri de vardır. Ağırlıkların belirlenmesi modelin öğrenmesine ve hızına etki etmektedir.

Ağırlık belirleme yöntemlerini ve etkilerini aşağıdaki gibi tanımlayabiliriz;


“ W ” ağırlıkları eğer başlangıçta sıfır olarak seçersek matris çarpımı bir toplam olduğu için, girdi değerleri, çıktı değerleri ile aynı olur. Bu yüzden w ağırlıkları model başlangıcında 0 olarak belirlenmemelidir. Eğer W ağırlıkları model başlangıcında rastgele küçük sayılardan seçilirse model küçük ağırlarda çalışır fakat ağ katmanları arasında aktivasyonun heterojen bir şekilde dağılımına neden olur.

3.6.7 Aktivasyon İşlemleri

Aktivasyon fonksiyonları, gizli katmanlarda $y = f(x, w)$ şeklindeki lineer bir fonksiyonu matris çarpımı yapıp nöronların ağırlığı hesaplandıktan sonra doğrusal olmayan (non-linear) bir değere dönüştürülerek çıktı elde edilir. Derin öğrenme yöntemleri de doğrusal olmayan sorunların çözümünde diğerlerine göre daha avantajlıdır. Derin

öğrenme ile çözülmeye çalışılan sorunlar genelde doğrusal olmayan non-linear bir problemdir. Kısacası aktivasyon fonksiyonları çok katmanlı yapay sinir ağlarında doğrusal olmayan (non-linear) dönüşüm işlemlerini gerçekleştirmek için kullanılmaktadır. Hidden layer'larda(gizli katmanlarda) geri türev alabilmek (gradient decent hesaplama) için (derin öğrenmede fark geri türevle alınır) gizli katmanların (hidden layer) çıktısı bazı aktivasyon fonksiyonları ile normalize edilmektedir (Çarkacı.N 2018). Aktivasyon fonksiyonlarının bazıları Şekil 3.18'de fonksiyon grafikleri ile birlikte gösterilmiştir. En kullanışlı olarak ReLu gösterilebilir. ReLu da diğerlerine göre parametreler daha hızlı bir şekilde öğrenilmektedir. ReLU'nun kaçırdığı eksi değerleri yakalamak için PReLU kullanılır. Eğer negatif değerleri yakalamak istiyorsak PReLU kullanılmalıdır.


Kolay türev alabilmek ve geriye dönük düzeltmeler yapabilmek için aktivasyon fonksiyonlarını gradient descent ile kullanabiliriz. Genellikle ileri beslemeli (Feedforward) ağlarda ReLu versiyonları kullanılmaktadır.



Şekil 3. 18. Bazı aktivasyon fonksiyonlarının grafikleri

3.6.8 Seyreltme İşlemleri

FC katmanlarda belirli bir alt değer altındaki değerlerin seyreltilmesinin yani istenmeyen verilerin unutulması öğrenimi arttırdığı görülmüştür. (Çarkacı.N 2018).




Şekil 3. 19. Dropout İşlemi (Scheau.C 2016).

Genellikle seyreltme (Dropout) değeri olarak 0.5 seçilmektedir. Farklı değerlerde kullanılabilir. Bu durum seçilen probleme ve veri setine göre değişebilir. Seyreltme (Dropout) için rastgele eleme yöntemi kullanılabildiği gibi eşik değeri olarak [0,1] aralığında bir değer olarak da kullanılabilir. Her katmanlarda farklı dropout değeri kullanılabilir.

3.6.9 Katman Sayısı ve Nöron Sayısı

Derin öğrenme yönteminin en önemli özelliği ve bunu başka nöral networklerden ayıran özelliği karışık problemlerde iyi sonuç vermesidir. Bunu sağlayan özelliği ise katman sayısıdır. Derin öğrenme derinlik kavramı da buradan gelmektedir. Derin öğrenme de katman sayısı arttıkça modelin daha iyi öğrendiği bilinmektedir




Şekil 3. 20. Yapay Sinir Ağı (Parbhakar.A 2016).

Çok katmanlı yapay sinir ağlarında, çok katmanlı bir yapı kurulması için modelin temeli buna uygun olarak tasarlanmalıdır. Katman sayısının artması demek geri besleme (backproagation) etkisinin birinci katmanlara az ulaşabilmesi demektir. Katman sayısının gereğinden fazla artırılması belli bir noktadan sonra etkisinin azalmasına neden olmaktadır. Hiperparametreleri değiştirerek bu sorun çözülüp modelin başarımı artırılmaya çalışılmalıdır.

Nöronların sayısı hafızadaki bilgi sayısını belirtir. Bellek ihtiyacı ve hesaplama zamanını artması nöron sayısının fazla olmasından kaynaklanmaktadır. Eğer çalıştığınız ortamda GPU yoksa bu özellikleri dikkate almanız gerekmektedir.

Nöronların sayılarının yetersiz olması yetersiz uyumaya neden olmaktadır. Bunlardan ayrı olarak da nöronların sayısının katmanlar içerisinde farklı dağılmasını sağlamak, yani ilk katmanlarda fazla nöron varken devam eden katmanlarda küçültülerek devam edilmesi “regularization” (başarı iyileştirme) etkisi oluşturur (Çarkacı.N 2018).

3.6.10 Konvolüsyon Sinir Ağı (CNN) Kernel Boyutu



Şekil 3. 21. Örnek Evrişimsel Sinir Ağı (CNN) Yapısı (Anonim 2018)

CNN’lerin her katmanında matrisler ile birlikte işlemleri gerçekleştiren” kerneller” bulunmaktadır. Bu yapılar Gabor filtrelerine benzemektedirler. Bu yapıların boyutları boyutları, öğrenme açısından oldukça etkilidirler. Kernel boyutunu belirlemek verilerin birbirlerini ne kadar etkileyeceğini belirlemekle aynı anlama gelmektedir. Evrişimli sinir ağlarında genellikle 3x3, 5x5, 7x7 boyutların da kernel kullanılmaktadır. Kernel boyutlarının büyük olması sonucunda oluşacak yeni görüntünün boyutları küçük olacaktır. Böylelikle veri kaybını düşük tutmak için küçük boyutlu kerneller kullanılmalıdır. Kenar bulma işlemi yapılırken pikselin sağına-soluna üstüne-altına bakılabilmesi için genellikle tek sayılardan oluşan filtreler kullanılır.

4. ARAŞTIRMA BULGULARI ve TARTIŞMA

4.1 Kullanılan Veri Tabanı ve Özellikleri

Bu çalışmamızda 210 yüksek dereceli glioma (HGG) ve 75 düşük dereceli glioma (LGG) hasta taraması içeren BRATS 2017 veri seti kullanılmıştır (Menze BH 2015, Bakas, Akbari et al. 2017, Bakas, Akbari et al. 2017). Bu veri seti kullanılarak çalışmamız test edilmiş ve değerlendirilmiştir. BRATS 2017 veri setinde her hasta için T1 ağırlıklı (T1), T1 ağırlıklı görüntüleme ile gadolinyum artırıcı kontrast (T1c), T2 ağırlıklı (T2) ve FLAIR görüntüleri mevcuttur. Veri setinde hastalar için, T1, T2 ve FLAIR görüntüleri $1 \times 1 \times 1 \text{ mm}^3$ boyutlarına getirilip T1c verilerine kaydedilmiştir. Bununla birlikte her bir dizinin ortalaması alınıp standart sapmasına bölünerek veri normalizasyonu uygulanmıştır. Bunlara ek olarak veri setimizde 4 etikete sahip manuel segmentasyonlar bulunmaktadır.

Manuel segmentasyonlar, modeli eğitmek ve performansını değerlendirmek için kullanılmıştır. Bu çalışmada, ödem Ödem bölgelerini segmentlere ayırmak için FLAIR görüntülerini kullanıldı. Ek olarak, ilerleyen tümörün tanımlanması için T1c verileri kullanıldı. Bu da hem performansı artırmak hem de veri kirliliğini ortadan kaldırmak açısından faydalıdır.

4.2 Veri Büyütme

Veri büyütme işleminin amacı, daha fazla eğitim verisi üreterek ağımızın performansını iyileştirmektir. Döndürme, kaydırma ve yakınlaştırma gibi basit dönüşümler sistemimizde istenilen verileri elde etmemizi sağlamadığı için ve görüntülerde bozulmalara yol açabildiği için kullanmadık. Makaslama işlemi, tümörün küresel şeklini yatay yönde bozabildiği için kullanılmadı (Dong, Yang et al. 2017). Bu problemlerle başa

çıkmak için, keyfi fakat makul şekillerde daha fazla eğitim verisi oluşturabilen “elastik distorsiyon” (Simard, Steinkraus et al. 2003) yöntemini uyguladık.

4.3 U-Net Tabanlı Derin Dönüşümlü Ağlar

Biyomedikal görüntülerin ayrıntılı desenler içerdiği ve kenarlarının değişken olduğu bilinmektedir. Bu tip görüntülerin segmentasyonu ve ayrıntılı bölütleme oluşturmak için görünimleri birleştiren atlamalı mimari kullanılmalıdır (Long, Shelhamer et al. 2015). Bu yöntem doğal görüntüler üzerinde başarılı sonuçlar ortaya koymuştur (Long, Shelhamer et al. 2015). Bu yöntem biyomedikal görüntülere de uygulanabilir (Drozdal, Vorontsov et al. 2016). Hücre izleme problemini çözmek için atlama mimarisini kullanan U-Net kullanıldı (Drozdal, Vorontsov et al. 2016).


U-Net tabanlı ağ mimarimiz, Şekil 1'de gösterildiği gibi bir alt örnekleme (kodlama) ve bir üst örnekleme (kod çözme) yolundan oluşur. Aşağı örnekleme de 5 tane konvolüsyon bloğu vardır. Her bloğun 3×3 filtre boyutu, her iki yönde 1 adımı ve 1 ile 1024 arasında özellik harita sayısını artıran iki doğrultucu katman vardır.

Aşağı örnekleme için, maksimum 2×2 adımlı max pooling son blok hariç her bloğun sonuna uygulanır ve böylelikle özellik haritalarının boyutu 240×240 den 15×15 ' e kadar düşürülür.

Yukarı örnekleme yolunda, her blok, 3×3 filtre boyutu ve 2×2 adımlı bir dekonvolüsyon tabakası ile başlar, bu özellik her iki yönde özellik haritalarının boyutunu ikiye katlar, ancak özellik haritalarının sayısını yarıya düşürür. Özellik haritalarının boyutu 15×15 'ten 240×240 ' a kadar çıkar.

Her bir örnekleme bloğunda, iki tane birbirini izleyen katman, deconvolutional özellik haritalarının ve özellik haritalarının kodlama yolunun birleşimindeki özellik haritalarının sayısını azaltır. Orijinal U-Net mimarisinden (Drozdal, Vorontsov et al. 2016) farklı

olarak hem alt örnekleme hem de üst örnekleme yolunun tüm konvolüsyon katmanları için çıktı boyutunu korumak için sıfır kaydırma kullanılmaktadır. Son olarak, ön ve arka plan segmentasyonunu düzeltmek için ve özellik haritalarının sayısını azaltmak amacıyla 1×1 boyutunda kıvrımlı bir katman kullanılır. Ağda tam bağlı katman kullanılmaz.



Şekil 4. 1. U-Net modeli (Dong, Yang et al. 2017)

4.4 Eğitim ve Optimizasyon

Eğitim sürecinde her görüntüdeki pixeller etiketlenir. Ayrıca manuel olarak segmente edilmiş görüntülerde etiketlenir. Sonra bu iki görüntü karşılaştırılarak benzerlik oranı hesaplanır. Derin sinir ağlarının eğitimi, parametrelere göre maliyet fonksiyonunu en aza indirmek için stokastik gradyan tabanlı optimizasyon kullanılmasını gerektirir. Parametreleri tahmin etmek için uyarlamalı moment tahmincisi olan Adam yöntemi

kullanıldı (Kinga and Adam 2015). Genel olarak, Adam mevcut gradyanların hareketli ortalamasını güncellemek ve düzeltmek için ilk ve ikinci gradyan değerlerini kullanır. Adam optimizier parametreleri, öğrenme oranı = 0.0001, maksimum epoch sayısı = 100, tüm ağırlıklar = 0 ve standart sapma = 0 olarak normal dağılıma göre başlatıldı. Ayrıca epoch sayısı 20, 25, 50 olarak değiştirilip sonuçlar gözlemlendi.

4.5 Performans Ölçütleri

Değerlendirme HGG ve LGG verileri sırasıyla her hasta için, üç subtumoral bölgede doğrulandı.

- a. Tüm tümör bölgesi
- b. Çekirdek tümör bölgesi
- c. Artmakta olan tümör bölgesi

Manuel olarak etiketlenmiş beyin tümöral bölgeleri ve kullanılan yöntem segmentasyon sonuçlarının karşılaştırılarak, çalışma sonuçlarının performansı belirlemek için her tümöral bölge için segmentasyon sonuçları Denklem 4.1 ile tanımlan Doğruluk büyüklüğü kullanılarak değerlendirildi. Doğruluk, her sınıf için doğru belirlenmiş piksellerin yüzdesini gösterir. Her sınıf için elde edilen Gerçek Pozitif test sonucu TP (True Positive), Hatalı Pozitif test sonucu FP (False Pozitive) ve Hatalı Negatif test sonucu FN (False Negative) ile tanımlanmaktadır. Çalışma sonuçları değerlendirilirken, her sınıf için elde edilen Doğruluk büyüklüğünün ortalaması Ortalama Doğruluk olarak belirlenmiş ve çizelgelerde verilmiştir.

$$\text{Doğruluk Skoru} = \frac{TP}{TP + FN} \quad (\text{Denklem 4.1})$$

Tek başına kullanılan Doğruluk büyüklüğü basit ve faydalı olmasına rağmen, mesela tüm pikseller hatalı olarak belirli bir sınıf olarak tespit edildiği durumda o sınıf doğruluğu açısından yüksek sonuç vermesine rağmen bütün sınıfların test sonuçları açısından bu test

başarılı olarak değerlendirilmemelidir. Bu sebeple Doğruluk yerine daha yaygın olarak Denklem 4.2 ile tanımlanan IoU (Intersection over Union, Kesişimin Birleşime Oranı) Skoru kullanılır.

$$IoU\ Skoru = TP / (TP + FP + FN) \quad (\text{Denklem 4.2})$$

Son olarak, her bir sınıfın öngörülen sınırının gerçek sınırla ne kadar uyumlu olduğunu gösteren ve insan kalitatif değerlendirmesi ile IoU skorundan daha iyi olan ortalama BF skoru da değerlendirme sonuçları çizelgelerine eklenmiştir.

4.6 Deneysel Sonuçlar

Bu çalışmada temel olarak dokuz farklı test gerçekleştirilerek kullanılan modelin performansı belirlenmeye çalışılmıştır. Her test altında farklı parametreler kullanılarak, bazı durumlarda birden çok parametre kombinasyonu ayrı ayrı denenerek elde edilen sonuçlar ilgili çizelgelerde verilmiştir.

Yapılan testler NVDI GTX 1070 (8GB) GPU kullanılarak tamamlanmıştır.

Test 1: Bu testte ağ eğitilirken veri tabanı olarak HGG ve LGG verileri birlikte kullanılmıştır. Toplamda 44175 adet görüntü ile eğitim yapılmıştır. Testte kullanılan parametreler aşağıdaki çizelgelerde verilmiştir.

Çizelge 4.1. Test 1 model eğitiminde kullanılan parametreler

| Veritabanı | LearningRate | MiniBatchSize | MaxEpoch |
|------------|--------------|---------------|----------|
| HGG+LGG | 0.0001 | 10 | 25 |

Eğitim süresi yaklaşık 22 saat sürmüş ve Çizelge 4.2’de verilen test sonuçları elde edilmiştir.

Çizelge 4.2. HGG ve LGG verileri için 25 epoch ile elde edilen test sonuçları

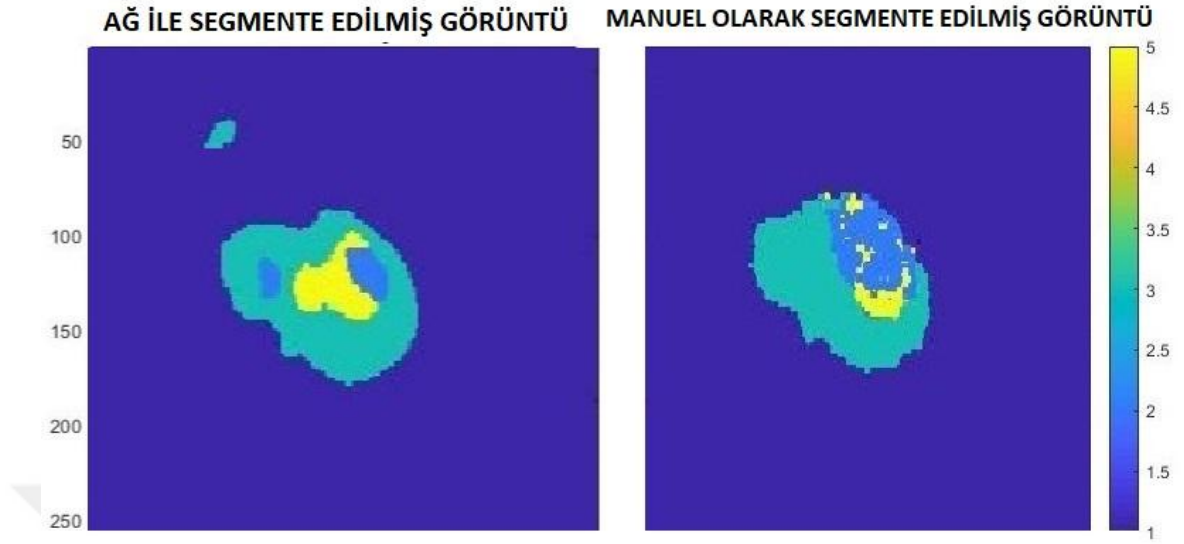
| Epoch sayısı | Kullanılan veri | Ortalama Doğruluk | Ortalama IoU | Ortalama BF Skoru |
|--------------|-----------------|-------------------|--------------|-------------------|
| 25 | HGG+LGG | 0,79684 | 0,70109 | 0,91246 |

Sonuçlar değerlendirildiğinde %79 seviyelerinde başarı sağlandığı görülmüştür. Ayrıca belirlenen üç subtomoral bölge için ayrı ayrı başarı oranları Çizelge 4.2.’de gösterilmiştir. Bu verilerin değerlendirilmesinden başarının Ödem bölge tespitinde en fazla oranda olduğu görülmektedir.

Çizelge 4.3. HGG ve LGG verileri için 25 epoch ile elde edilen üç bölge test sonuçları

| Epoch sayısı | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|----------------|-------------------|--------------|------------------|
| Ödem | 0.75662 | 0.61081 | 0,76305 |
| Çekirdek Tümör | 0,70142 | 0,60069 | 0,62126 |
| Artan Tümör | 0,73031 | 0,59545 | 0,69097 |

Elde edilen eğitim ağı kullanılarak örnek olarak tek bir görüntü ile segmentasyon işlemi yapıldığında, Şekil 4.2 ile gösterilen sınıflandırma sonuçları elde edilmektedir.



Şekil 4. 2. Sol: Eğitim sonucunda elde edilmiş ağ ile örnek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiketi. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi)

Test 2: Bu ağ eğitilirken veri tabanı olarak HGG ve LGG verileri ayrı ayrı kullanılmıştır. Toplamda HGG için 32550, adet görüntü ile eğitim yapılmıştır. Testimizde kullanılan parametreler aşağıdaki çizelgede verilmiştir.

Çizelge 4.4. Test 2 model eğitiminde kullanılan parametreler

| Veritabanı | LearningRate | MiniBatchSize | MaxEpoch |
|------------|--------------|---------------|----------|
| HGG | 0.0001 | 10 | 20 |

Bu parametreler kullanılarak eğitim başlatılmış ve eğitim yaklaşık olarak 14 saat sürede tamamlanmıştır. Eğitim elde edilen eğitim ağı test edildiği zaman aşağıdaki sonuçlar elde edilmiştir.

Çizelge 4.5. HGG verileri için 20 epoch ile elde edilen test sonuçları

| Epoch sayısı | Kullanılan veri | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|--------------|-----------------|-------------------|--------------|------------------|
| 20 | HGG | 0,78373 | 0,70769 | 0,91911 |

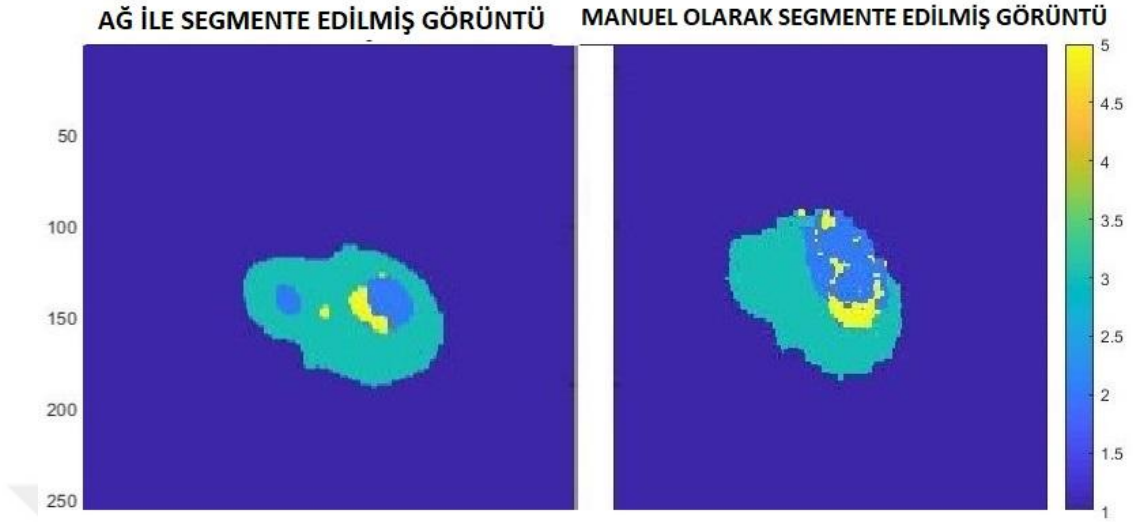
İkinci test sonuçlarına bakıldığında bakıldığın da %78 seviyelerinde başarı sağlandığı görülmüştür. İlk teste göre başarı oranı genel olarak azaldığı görülmüştür. Bunun nedeni olarak epoch sayısının azalması ve sadece HGG verilerinin kullanılması olarak gösterilebilir. Ayrıca belirlenen üç subtomoral bölge için ayrı ayrı başarı oranları Çizelge 4.6' da gösterilmiştir.

Çizelge 4. 6. HGG verileri için 20 epoch ile elde edilen üç bölge test sonuçları

| Epoch sayısı | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|----------------|-------------------|--------------|------------------|
| Ödem | 0.77662 | 0.64273 | 0,80671 |
| Çekirdek Tümör | 0,64938 | 0,56941 | 0,66209 |
| Artan Tümör | 0,71507 | 0,62119 | 0,69732 |

Çizelge 4.6'da görüldüğü üzere genel başarı azalmasına rağmen Ödem bölgesi belirlemede başarı artmıştır. Bunun nedeni olarak sadece HGG verilerinin kullanımı gösterilebilir.

Elde edilen eğitim ağı kullanılarak örnek olarak tek bir görüntü ile segmentasyon işlemi yapıldığında, Şekil 4.3 ile gösterilen sınıflandırma sonuçları elde edilmektedir.



Şekil 4. 3. Sol: Eğitim sonucunda elde edilmiş ağ ile örnek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiketi. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi)

Test 3: Bu ağ eğitilirken veri tabanı olarak LGG verileri kullanılmıştır. Toplamda LGG için 11625 adet görüntü ile eğitim yapılmıştır. Testimizde kullanılan parametreler Çizelge 4.7 ile verilmiştir.

Çizelge 4.7. Test 3 model eğitiminde kullanılan parametreler

| Veritabanı | LearningRate | MiniBatchSize | MaxEpoch |
|------------|--------------|---------------|----------|
| LGG | 0.0001 | 10 | 20 |

Bu parametreler kullanılarak eğitim başlatılmış ve eğitim yaklaşık olarak 05 saat sürede tamamlanmıştır. Eğitim elde edilen eğitim ağı test edildiği zaman Çizelge 4.8'deki sonuçlar elde edilmiştir.

Çizelge 4.8. LGG verileri için 20 epoch ile elde edilen test sonuçları

| Epoch sayısı | Kullanılan veri | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|--------------|-----------------|-------------------|--------------|------------------|
| 20 | LGG | 0,69774 | 0,63393 | 0,90255 |

İkinci testten farklı olarak sadece LGG verileri kullanılmıştır. Başarı oranı genel olarak düşmüştür. Bunun nedeni olarak görüntü sayısının azalması gösterilebilir.

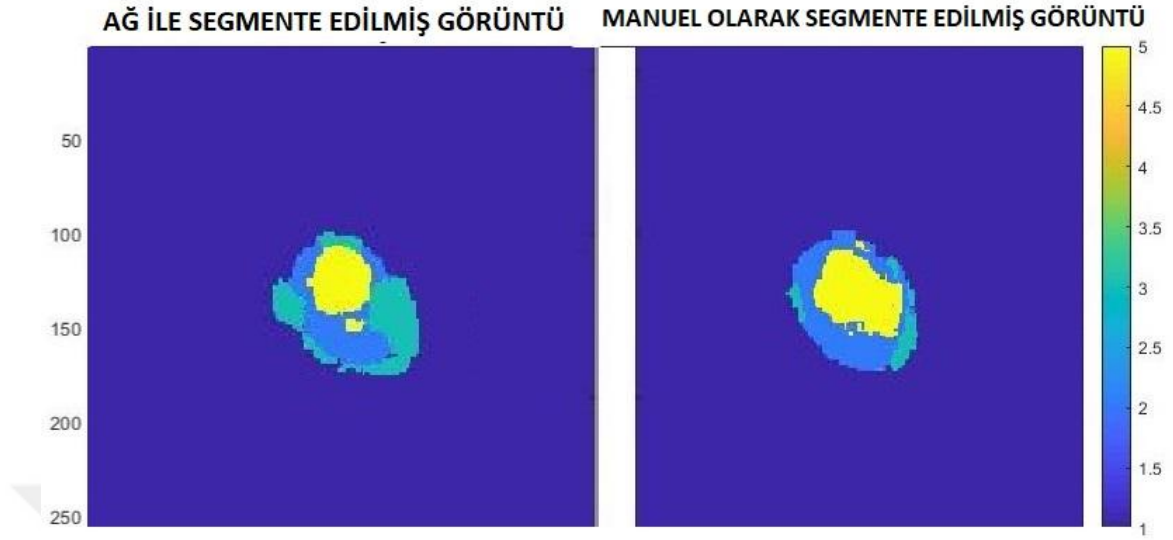
Ayrıca belirlene üç subtomoral bölge için ayrı ayrı başarı oranları Çizelge 4.9’da gösterilmiştir.

Çizelge 4.9. LGG verileri için 20 epoch ile elde edilen üç bölge test sonuçları

| Epoch sayısı | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|----------------|-------------------|--------------|------------------|
| Ödem | 0.36318 | 0.33948 | 0,55092 |
| Çekirdek Tümör | 0,71892 | 0,65463 | 0,56850 |
| Artan Tümör | 0,70944 | 0,54406 | 0,64228 |

Çizelge 4.9. incelendiğinde sadece LGG verilerinin kullanılması Çekirdek tümör bölgelerinde başarıyı artırmış fakat Ödem bölgesi tespitinde başarı ciddi bir oranda düşmüştür.

Elde edilen eğitim ağı kullanılarak örnek olarak tek bir görüntü ile segmentasyon işlemi yapıldığında, Şekil 4.4 ile gösterilen sınıflandırma sonuçları elde edilmektedir.



Şekil 4. 4. Sol: Eğitim sonucunda elde edilmiş ağ ile örnek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiketi. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi)

Test 4: Bu ağ eğitilirken veri tabanı olarak HGG ve LGG verileri birlikte kullanılmıştır. Toplamda 44175 adet görüntü ile eğitim yapılmıştır. Testte kullanılan parametreler aşağıdaki çizelgede verilmiştir.

Çizelge 4.10. Test 4 model eğitiminde kullanılan parametreler

| Veritabanı | LearningRate | MiniBatchSize | MaxEpoch |
|------------|--------------|---------------|----------|
| HGG+LGG | 0.0001 | 10 | 20 |

Bu parametreler kullanılarak eğitim başlatılmış ve eğitim yaklaşık olarak 20 saat sürede tamamlanmıştır. Eğitilen ağ test edildiğinde, Çizelge 4.11’deki sonuçlar elde edilmiştir.

Çizelge 4.11. HGG ve LGG verileri için 20 epoch ile elde edilen test sonuçları

| Epoch sayısı | Kullanılan veri | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|--------------|-----------------|-------------------|--------------|------------------|
| 20 | HGG+LGG | 0,77954 | 0,68059 | 0,90902 |

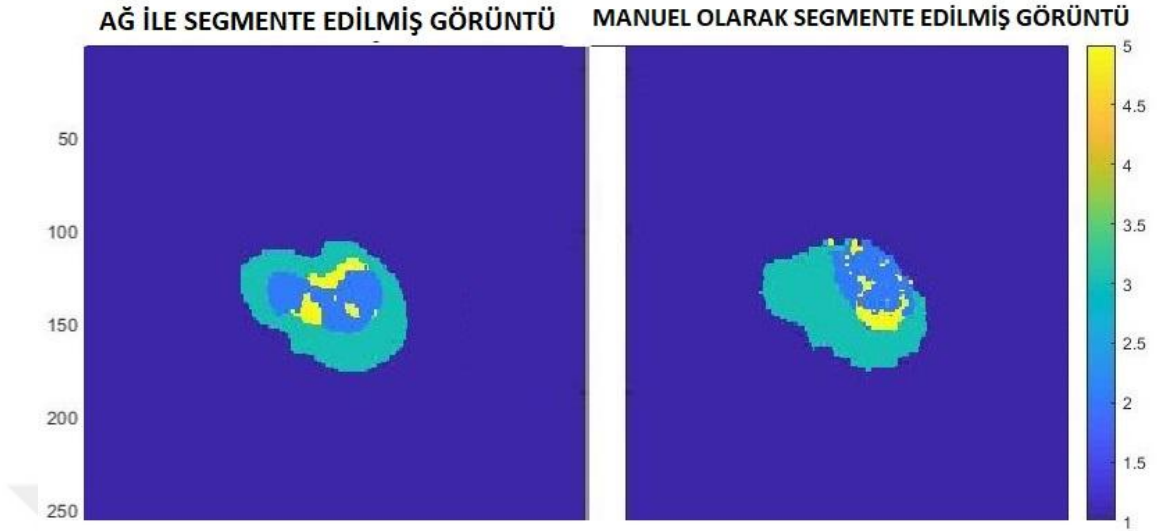
Sonuçlara bakıldığında HGG ve LGG verileri 20 epoch ile eğitildiğinde başarıda sadece HGG verilerinin kullanımına göre bir miktar düşüş olduğu görülmektedir. Bu da LGG verilerinin kullanılmasının başarının düşmesine neden olduğu gözlemlenmektedir.

Çizelge 4.12. HGG ve LGG verileri için 20 epoch ile elde edilen üç bölge test sonuçları

| Epoch sayısı | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|----------------|-------------------|--------------|------------------|
| Ödem | 0.76203 | 0.59736 | 0,75325 |
| Çekirdek Tümör | 0.69697 | 0.56925 | 0.61249 |
| Artan Tümör | 0,65990 | 0,55843 | 0,66899 |

Çizelgede görüldüğü üzere başarı oranlarının tüm bölgelerde düşmüş olduğu gözlemlenmektedir.

Elde edilen eğitim ağı kullanılarak örnek olarak tek bir görüntü ile segmentasyon işlemi yapıldığında, Şekil 4.5 ile gösterilen sınıflandırma sonuçları elde edilmektedir.



Şekil 4. 5. Sol: Eğitim sonucunda elde edilmiş ağ ile örnek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiketi. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi)

Test 5: Bu ağ eğitilirken veri tabanı olarak HGG verileri kullanılmıştır. Toplamda HGG için 32550 adet görüntü ile eğitim yapılmıştır. Testimizde kullanılan parametreler aşağıda Çizelge 4.13’de verilmiştir.

Çizelge 4.13. Test 5 model eğitiminde kullanılan parametreler

| Veritabanı | LearningRate | MiniBatchSize | MaxEpoch |
|------------|--------------|---------------|----------|
| HGG | 0.0001 | 10 | 50 |

Bu parametreler kullanılarak eğitim başlatılmış ve eğitim yaklaşık olarak 36 saat sürede tamamlanmıştır. Eğitilen ağ test edildiğinde, Çizelge 4.14’deki sonuçlar elde edilmiştir.

Çizelge 4.14. HGG verileri için 50 epoch ile elde edilen test sonuçları

| Epoch sayısı | Kullanılan veri | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|--------------|-----------------|-------------------|--------------|------------------|
| 50 | HGG | 0,79310 | 0,72027 | 0,92319 |

Bu testimizde epoch sayısı 50 çıkarılıp sadece HGG verileri kullanılarak eğitim yapılmıştır. Genel başarı bir önceki HGG verileri ile yapılan teste göre bir miktar artmıştır.

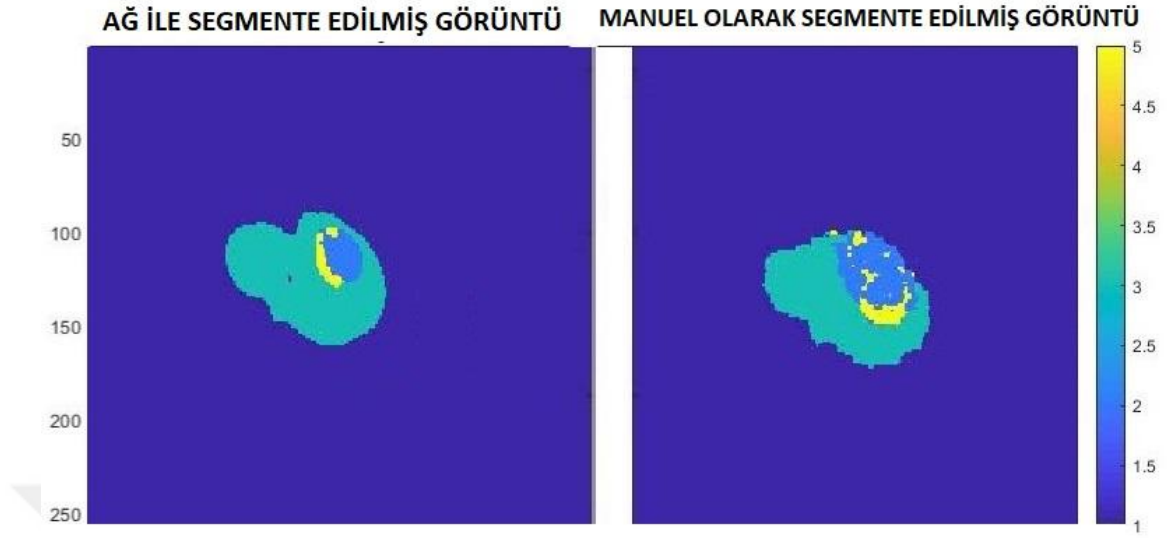
Ayrıca belirlenen üç subtomoral bölge için ayrı ayrı başarı oranları Çizelge 4.15’de gösterilmiştir.

Çizelge 4.15. HGG verileri için 50 epoch ile elde edilen üç bölge test sonuçları

| Epoch sayısı | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|----------------|-------------------|--------------|------------------|
| Ödem | 0.78379 | 0.65789 | 0,81813 |
| Çekirdek Tümör | 0,66145 | 0,58866 | 0,68139 |
| Artan Tümör | 0,72775 | 0,63700 | 0,71421 |

Çizelge 4.15. incelendiğinde sadece HGG ile eğitilmiş ağda her bölümde başarı oranı arttığı görülmektedir. Bunun nedeni olarak hem epoch sayısının artırılması hem de veri sayısının artmış olması gösterilebilir.

Elde edilen eğitim ağı kullanılarak örnek olarak tek bir görüntü ile segmentasyon işlemi yapıldığında, Şekil 4.6 ile gösterilen sınıflandırma sonuçları elde edilmektedir. Kullanılan görüntü HGG verilerinden alınmıştır.



Şekil 4. 6. Sol: Eğitim sonucunda elde edilmiş ağ ile örnek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiketi. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi)

Test 6: Bu ağ eğitilirken veri tabanı olarak LGG verileri kullanılmıştır. Toplamda LGG için 11625 adet görüntü ile eğitim yapılmıştır. Testimizde kullanılan parametreler aşağıda Çizelge 4.16’da verilmiştir.

Çizelge 4.16. Test 6 model eğitiminde kullanılan parametreler

| Veritabanı | LearningRate | MiniBatchSize | MaxEpoch |
|------------|--------------|---------------|----------|
| LGG | 0.0001 | 10 | 50 |

Bu parametreler kullanılarak eğitim başlatılmış ve eğitim yaklaşık olarak 14 saat sürede tamamlanmıştır. Eğitilen ağ test edildiğinde, Çizelge 4.17’deki sonuçlar elde edilmiştir.

Çizelge 4.17. LGG verileri için 50 epoch ile elde edilen test sonuçları

| Epoch sayısı | Kullanılan veri | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|--------------|-----------------|-------------------|--------------|------------------|
| 50 | LGG | 0,78076 | 0,72063 | 0,92078 |


Çizelge 4.17’de görüldüğü gibi epoch sayısı 50 çıkarılıp sadece LGG verileri ile ağ eğitildiğinde başarı oranı Test 3 göre arttığı görülmektedir. Bunun nedeni olarak yine epoch sayısının artması gösterilebilir.

Çizelge 4. 18. LGG verileri için 50 epoch ile elde edilen üç bölge test sonuçları

| Epoch sayısı | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|----------------|-------------------|--------------|------------------|
| Ödem | 0.60267 | 0.53417 | 0,69947 |
| Çekirdek Tümör | 0,81015 | 0,74089 | 0,67967 |
| Artan Tümör | 0,71057 | 0,60958 | 0,69729 |

Çizelge 4.18 incelendiğinde epoch sayısının artırılması ile çekirdek tümör tespitinin ciddi oranda arttığı gözlemlenmektedir.

Elde edilen eğitim ağı kullanılarak örnek olarak tek bir görüntü ile segmentasyon işlemi yapıldığında, Şekil 4.7 ile gösterilen sınıflandırma sonuçları elde edilmektedir. Kullanılan görüntü LGG verilerinden alınmıştır.



Şekil 4.7. Sol: Eğitim sonucunda elde edilmiş ağ ile örnek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiketi. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi)

Test 7: Bu ağ eğitilirken veri tabanı olarak HGG ve LGG verileri birlikte kullanılmıştır. Toplamda 44175 adet görüntü ile eğitim yapılmıştır. Testimizde kullanılan parametreler aşağıdaki Çizelge 4.19’da verilmiştir.

Çizelge 4.19. Test 7 model eğitiminde kullanılan parametreler

| Veritabanı | LearningRate | MiniBatchSize | MaxEpoch |
|------------|--------------|---------------|----------|
| HGG+LGG | 0.0001 | 10 | 50 |

Bu parametreler kullanılarak eğitim başlatılmış ve eğitim yaklaşık olarak 52 saat sürede tamamlanmıştır. Eğitilen ağ test edildiğinde, Çizelge 4.20’deki sonuçlar elde edilmiştir.

Çizelge 4.20. HGG ve LGG verileri için 50 epoch ile elde edilen test sonuçları

| Epoch sayısı | Kullanılan veri | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|--------------|-----------------|-------------------|--------------|------------------|
| 50 | HGG+LGG | 0.78905 | 0.70600 | 0.91432 |

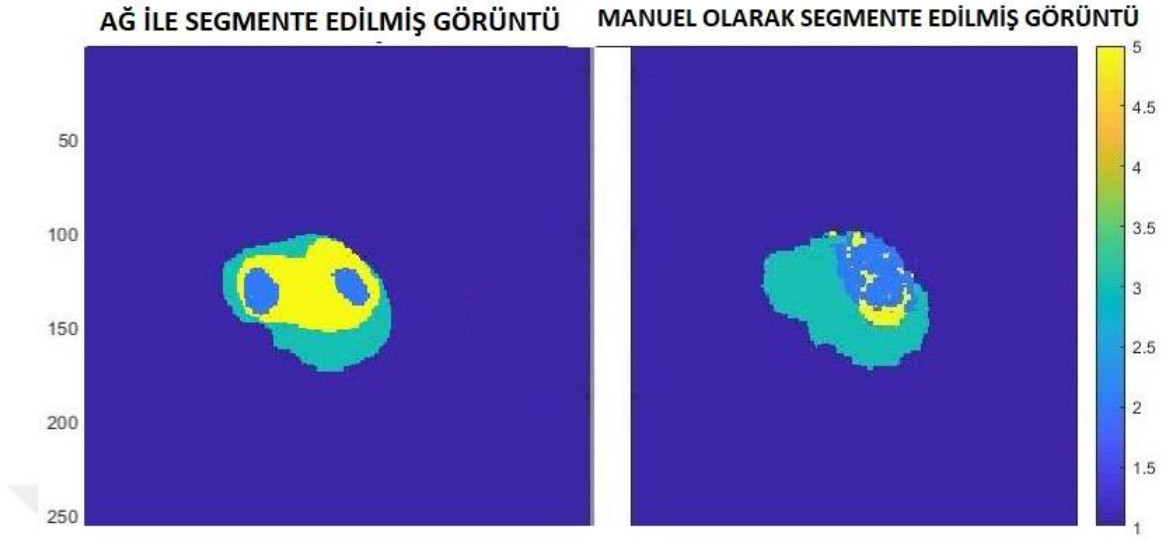
Sonuçlara bakıldığında HGG ve LGG verileri 50 epoch ile eğitildiğinde başarıda sadece HGG verilerinin kullanımına göre bir miktar düşüş olduğu görülmektedir. Bu da LGG verilerinin kullanılmasının başarının düşmesine neden olduğu gözlemlenmektedir.

Çizelge 4.21. HGG ve LGG verileri için 50 epoch ile elde edilen üç bölge test sonuçları

| Epoch sayısı | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|----------------|-------------------|--------------|------------------|
| Ödem | 0.76159 | 0.62118 | 0.76868 |
| Çekirdek Tümör | 0.66673 | 0.60137 | 0.62056 |
| Artan Tümör | 0.72858 | 0.60396 | 0.69302 |

Çizelge 4.21’de görüldüğü üzere başarı oranları ödem bölümünde HGG ile yapılan testten düşük, LGG ile yapılandan daha yüksek başarı sağlanmıştır. Çekirdek tümörü tespitinde ise tam tersi durum görülmüştür.

Elde edilen eğitim ağı kullanılarak örnek olarak tek bir görüntü ile segmentasyon işlemi yapıldığında, Şekil 4.8 ile gösterilen sınıflandırma sonuçları elde edilmektedir.



Şekil 4.8. Sol: Eğitim sonucunda elde edilmiş ağ ile örnek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiketi. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi)

Test 8: Bu ağ eğitilirken veri tabanı olarak HGG verileri kullanılmıştır. Toplamda HGG için 32550 adet görüntü ile eğitim yapılmıştır. Testimizde kullanılan parametreler aşağıdaki Çizelge 4.22’de verilmiştir.

Çizelge 4.22. Test 7 model eğitiminde kullanılan parametreler

| Veritabanı | LearningRate | MiniBatchSize | MaxEpoch |
|------------|--------------|---------------|----------|
| HGG | 0.0001 | 10 | 100 |

Bu parametreler kullanılarak eğitim başlatılmış ve eğitim yaklaşık olarak 76 saat sürede tamamlanmıştır. Eğitilen ağ test edildiğinde, Çizelge 4.23’deki sonuçlar elde edilmiştir.

Çizelge 4.23. HGG verileri için 100 epoch ile elde edilen test sonuçları

| Epoch sayısı | Kullanılan veri | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|--------------|-----------------|-------------------|--------------|------------------|
| 100 | HGG | 0,80555 | 0,72988 | 0,92721 |

Bu testimizde epoch sayısı 100'e çıkartılarak ve sadece HGG verileri kullanılarak eğitim yapılmıştır. Genel başarı bir önceki HGG verileri ile yapılan teste göre bir miktar artmıştır.

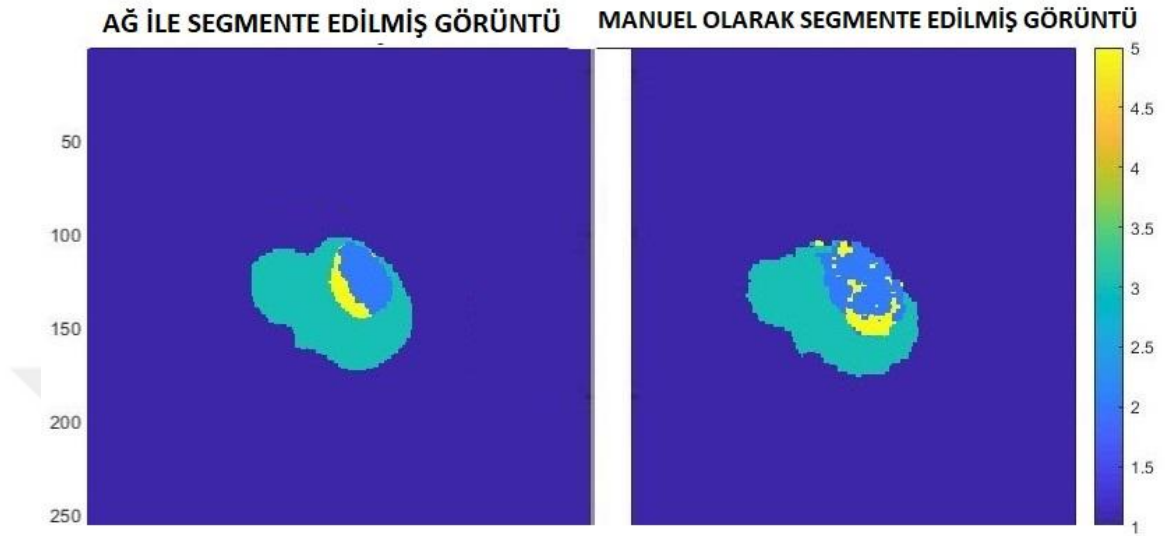
Ayrıca belirlenen üç subtomoral bölge için ayrı ayrı başarı oranları Çizelge 4.24'de gösterilmiştir.

Çizelge 4.24. HGG verileri için 100 epoch ile elde edilen üç bölge test sonuçları

| Epoch sayısı | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|----------------|-------------------|--------------|------------------|
| Ödem | 0,77599 | 0,66219 | 0,82396 |
| Çekirdek Tümör | 0,70496 | 0,60506 | 0,70248 |
| Artan Tümör | 0,74180 | 0,65460 | 0,72879 |

Çizelge 4.24 incelendiğinde sadece HGG ile eğitilmiş ağda Çekirdek ve Artan tümör bölgelerinin tespit edilmesindeki başarı artmış fakat Ödem bölgesi tespitindeki başarı oranının biraz azaldığı görülmektedir.

Elde edilen eğitim ağı kullanılarak örnek olarak tek bir görüntü ile segmentasyon işlemi yapıldığında, Şekil 4.9 ile gösterilen sınıflandırma sonuçları elde edilmektedir. Kullanılan görüntü HGG verilerinden alınmıştır.



Şekil 4.9. Sol: Eğitim sonucunda elde edilmiş ağ ile örnek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiketi. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi)

Test 9: Bu ağ eğitilirken veri tabanı olarak LGG verileri kullanılmıştır. Toplamda LGG için 11625 adet görüntü ile eğitim yapılmıştır. Testimizde kullanılan parametreler aşağıda Çizelge 4.25’de verilmiştir.

Çizelge 4.25. Test 8 model eğitiminde kullanılan parametreler

| Veritabanı | LearningRate | MiniBatchSize | MaxEpoch |
|------------|--------------|---------------|----------|
| LGG | 0.0001 | 10 | 100 |

Bu parametreler kullanılarak eğitim başlatılmış ve eğitim yaklaşık olarak 26 saat sürede tamamlanmıştır. Eğitilen ağ test edildiğinde, Çizelge 4.26’daki sonuçlar elde edilmiştir.

Çizelge 4.26. LGG verileri için 100 epoch ile elde edilen test sonuçları

| Epoch sayısı | Kullanılan veri | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|--------------|-----------------|-------------------|--------------|------------------|
| 100 | LGG | 0,78088 | 0,72883 | 0,92398 |

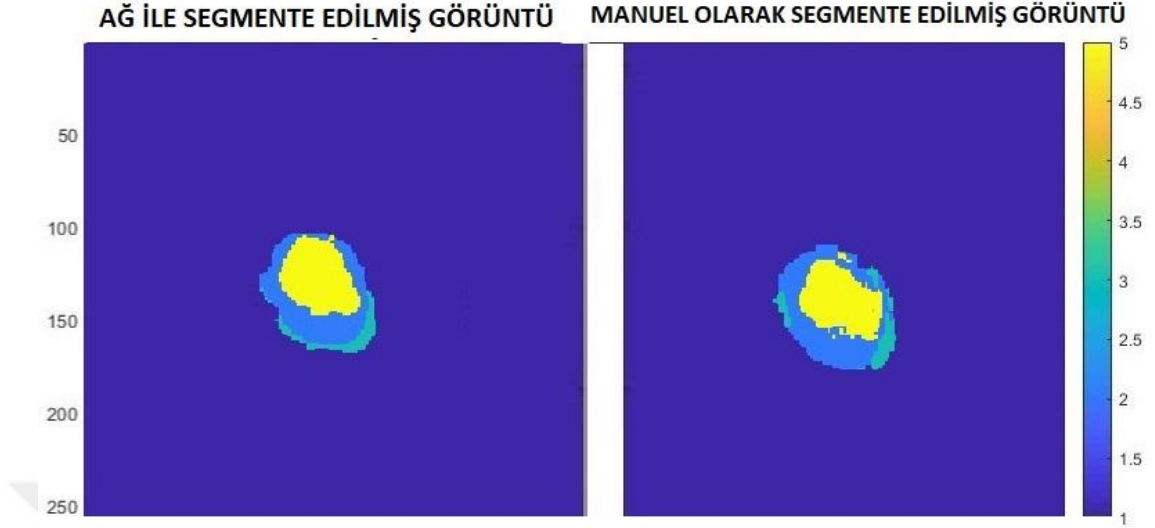
Çizelge 4.26’da görüldüğü gibi epoch sayısı 100’e çıkarılıp sadece LGG verileri ile ağ eğitildiğinde başarı oranı Test 5’e göre çok farklılık göstermemektedir.

Çizelge 4.27. LGG verileri için 100 epoch ile elde edilen üç bölge test sonuçları

| Epoch sayısı | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|----------------|-------------------|--------------|------------------|
| Ödem | 0.57556 | 0.53831 | 0,70922 |
| Çekirdek Tümör | 0,8068 | 0,75113 | 0,69371 |
| Artan Tümör | 0,74154 | 0,62797 | 0,71298 |

Çizelge 4.27 incelendiğinde epoch sayısının artırılması ile Çekirdek tümör tespitinde çok büyük bir farklılık oluşmamaktadır. Yaklaşık olarak aynı değerler elde edilmektedir. Sadece Artan tümör bölgesinde bir miktar artış gözlemlenmektedir.

Elde edilen eğitim ağı kullanılarak örnek olarak tek bir görüntü ile segmentasyon işlemi yapıldığında, Şekil 4.10 ile gösterilen sınıflandırma sonuçları elde edilmektedir. Kullanılan görüntü LGG verilerinden alınmıştır.



Şekil 4.10. Sol: Eğitim sonucunda elde edilmiş ağ ile örnek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiketi. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi)

Test 10: Bu ağ eğitilirken veri tabanı olarak HGG ve LGG verileri birlikte kullanılmıştır. Toplamda 44175 adet görüntü ile eğitim yapılmıştır. Testimizde kullanılan parametreler aşağıdaki Çizelge de verilmiştir.

Çizelge 4. 28. Test 9 model eğitiminde kullanılan parametreler

| Veritabanı | LearningRate | MiniBatchSize | MaxEpoch |
|------------|--------------|---------------|----------|
| HGG+LGG | 0.0001 | 10 | 100 |

Bu parametreler kullanılarak eğitim başlatılmış ve eğitim yaklaşık olarak 105 saat sürede tamamlanmıştır. Eğitilen ağ test edildiğinde, Çizelge 4.29'daki sonuçlar elde edilmiştir.

Çizelge 4. 29. HGG ve LGG verileri için 100 epoch ile elde edilen test sonuçları

| Epoch sayısı | Kullanılan veri | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|--------------|-----------------|-------------------|--------------|------------------|
| 100 | HGG+LGG | 0,77761 | 0,71079 | 0,91632 |

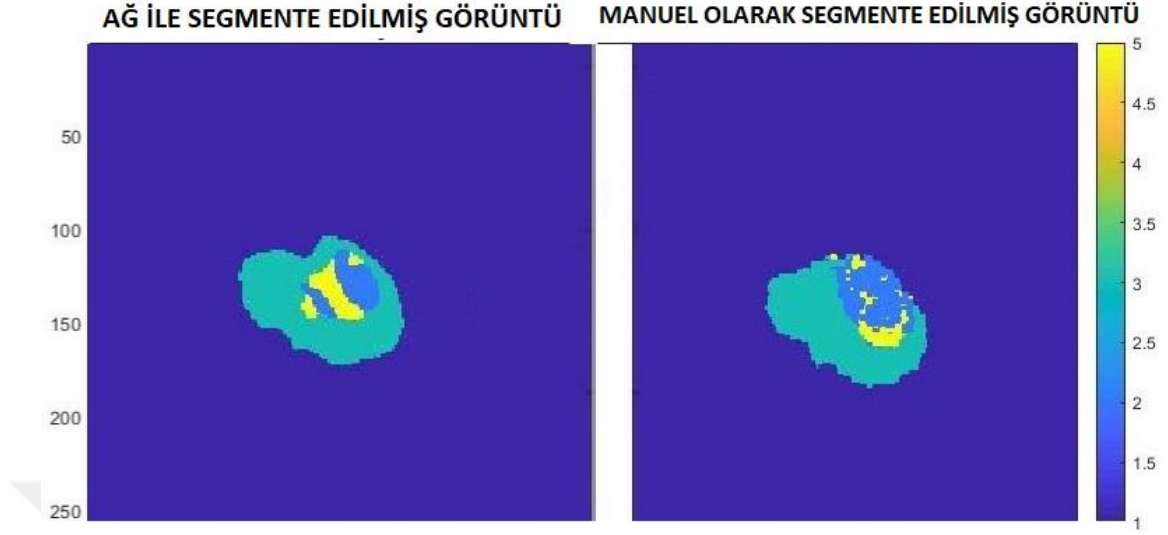
Sonuçlara bakıldığında HGG ve LGG verileri 100 epoch ile eğitildiğinde başarıda sadece HGG veya sadece LGG verilerinin kullanımına göre bir miktar düşüş olduğu görülmektedir.

Çizelge 4. 30. HGG ve LGG verileri için 100 epoch ile elde edilen üç bölge test sonuçları

| Epoch sayısı | Ortalama Doğruluk | Ortalama IoU | Ortalama BFscore |
|----------------|-------------------|--------------|------------------|
| Ödem | 0.70885 | 0.62029 | 0,78337 |
| Çekirdek Tümör | 0.68992 | 0.62583 | 0.64691 |
| Artan Tümör | 0,71220 | 0,59962 | 0,68426 |

Çizelge 4.30'da görüldüğü üzere başarı oranları tüm bölgelerde düşmüş olduğu gözlemlenmektedir.

Elde edilen eğitim ağı kullanılarak örnek olarak tek bir görüntü ile segmentasyon işlemi yapıldığında, Şekil 4.11 ile gösterilen sınıflandırma sonuçları elde edilmektedir.



Şekil 4.11. Sol: Eğitim sonucunda elde edilmiş ağ ile örnek bir görüntünün segmentasyon sonucu; Sağ: Manuel olarak uzmanlar tarafında oluşturulan etiketi. (Sarı: Çekirdek tümörü, Mavi: Artan Tümörü, Yeşil: Ödem bölgesi)

Yapılan tüm testlerin sonuçları Doğruluk Skoru ve IoU değerlendirme türlerine göre ve veri seti seçimine göre Çizelge 4.31.'de ve Çizelge 4.32.'de verilmiştir.

Çizelge 4. 31. Yapılan tüm testlerin Doğruluk Skoru sonuçları

| VeriTabanı | Epoch Sayısı | Doğruluk Skoru | | |
|------------|--------------|----------------|-----------------|-------------|
| | | Tüm Tümör | Çekirdek Tümörü | Artan Tümör |
| HGG+LGG | 25 | 0.79684 | 0.70142 | 0.73031 |
| HGG | 20 | 0.78373 | 0.64938 | 0.71507 |
| LGG | 20 | 0.69774 | 0.71892 | 0.70944 |
| HGG+LGG | 20 | 0.77954 | 0.69697 | 0.65990 |
| HGG | 50 | 0.79310 | 0.66145 | 0.72775 |
| LGG | 50 | 0.78076 | 0.81015 | 0.71057 |
| HGG+LGG | 50 | 0.78905 | 0.66673 | 0.72858 |
| HGG | 100 | 0.80555 | 0.70469 | 0.74180 |
| LGG | 100 | 0.78088 | 0.80680 | 0.74154 |
| HGG+LGG | 100 | 0.77761 | 0.68992 | 0.71220 |

Çizelge 4. 32. Yapılan tüm testlerin IoU sonuçları

| VeriTabanı | Epoch Sayısı | IoU | | |
|------------|--------------|-----------|-----------------|-------------|
| | | Tüm Tümör | Çekirdek Tümörü | Artan Tümör |
| HGG+LGG | 25 | 0.70109 | 0.60090 | 0.59545 |
| HGG | 20 | 0.70769 | 0.56941 | 0.62119 |
| LGG | 20 | 0.63393 | 0.65463 | 0.54406 |
| HGG+LGG | 20 | 0.68059 | 0.56925 | 0.55843 |
| HGG | 50 | 0.72027 | 0.58866 | 0.63700 |
| LGG | 50 | 0.72063 | 0.74089 | 0.60958 |
| HGG+LGG | 50 | 0.70600 | 0.60137 | 0.60396 |
| HGG | 100 | 0.72988 | 0.60506 | 0.65460 |
| LGG | 100 | 0.72883 | 0.75113 | 0.62797 |
| HGG+LGG | 100 | 0.71079 | 0.62583 | 0.59962 |

4.7. Tartışma

Yapılan bu tez çalışmasında, beyin tümörü segmentasyon problemini çözmek için U-Net tabanlı bir model oluşturuldu. Bu model de veri büyütme işlemi gerçekleştirilip U-net modeliyle atlama mimarisi kullanılarak birleştirildi.

Çalışmamız sırasıyla HGG ve LGG vakaları için segmentasyon çalışmalarının doğruluk skoru sonuçlarını belirlemiştir. Veri tabanı olarak yalnız HGG, yalnız LGG ve HGG + LGG olmak üzere üç farklı veri tabanı kullanılmıştır. Her veri tabanı ile yapılan eğitimlerde epoch sayısı 20, 25, 50 ve 100 olarak değiştirilmiş ve sonuçlar ayrı ayrı çizelge haline getirilmiştir. Yaptığımız çalışmada veri tabanı olarak HGG verilerini kullandığımızda başarı oranının arttığı görülmektedir. Çalışmamızda sadece HGG veri tabanı kullanıldığında tam tümör segmentasyonları için iyi sonuçlar elde edilmiştir. LGG veri tabanı kullanıldığında ise Çekirdek tümör segmentasyonları için iyi sonuçlar elde edilmiştir. Fakat LGG verilerinde tüm tümör bölgesi tespiti sonuçları bozulmaktadır. Bunun nedeni olarak da LGG vakalarında tümör bölgelerinin sınırlarının belirlenmesinin zor olması ve eğitim veri tabanının yetersiz olması gösterilebilir. Çalışmamızda HGG veri tabanı ile tüm tümör bölgesi tespiti 0.80555 doğruluk skoru seviyelerine ulaşmıştır. Çekirdek tümörü ise 0.70469 doğruluk skoru seviyelerine ulaşmıştır. LGG veri tabanı ile tüm tümör bölgesi tespiti 0.78088 doğruluk skoru seviyelerine ulaşmıştır. Çekirdek tümörü ise 0.81015 doğruluk skoru seviyelerine ulaşmıştır. HGG+LGG veri tabanı ile tüm tümör bölgesi tespiti 0.77954 doğruluk skoru seviyelerine ulaşmıştır. Çekirdek tümörü ise 0.70142 doğruluk skoru seviyelerine ulaşmıştır.

Tez sonuçlarının geliştirilebilmesi için ileride başka veri setlerinde de uygulanması düşünülmektedir. Bu şekilde daha objektif olarak değerlendirilmiş olur. Ayrıca oluşturduğumuz ağda kullanılan bazı parametrelerin farklı varyasyonları kullanılarak daha iyi sonuçlar elde edilebilir. Bunlara ek olarak LGG görüntülerinin sayısının az olması ve LGG türünde olan tümörlerin daha zor saptanması nedeniyle bu kısımdaki test sonuçlarımız daha düşük olduğu görülmüştür. Bu sebeple LGG veri setinin artırılmasının gerekli olduğu ve ayrıca daha iyi teknolojiye sahip MR görüntülerin kullanılması

durumunda sınıflandırma sonuçlarında iyileşme olacağı da düşünülmektedir.



5. SONUÇ

Bu çalışmada beyin tümörlerinin belirlenerek segmentasyonunun yapılması için bir yöntem geliştirilip, uygulanmıştır. Bunu gerçekleştirirken U-Net Tabanlı CNN ve Brats 2017 veri seti kullanılmıştır.

Çalışmamızda özellikle çekirdek tümörlerinin segmentasyonun da gözle görülür derecede iyi sonuçlar elde edilmiştir. Bu çalışma manuel yöntemleri kullanmadan hastaya özel bir beyin tümörü segmentasyon modelini gerçekleştirmeyi sağlar. Bunun sonucunda da teşhis ve tedavi planlaması daha kolay hale gelebilecektir.

KAYNAKÇA

- Arakeri, M. P. and G. R. M. Reddy (2013). "Computer-aided diagnosis system for tissue characterization of brain tumor on magnetic resonance images." *Signal, Image and Video Processing* 9(2): 409-425.
- Anonim. (2009). "Emar Nedir? (MR & MRG & Manyetik Rezonans Görüntüleme)." from <https://www.memorial.com.tr/saglik-rehberleri/manyetik-rezonans-goruntuleme-e-mrg-mr-nedir/#quicklink3> (10/09/2017).
- Anonim. (2016). "Deep learning.ai." from <https://www.coursera.org/deeplearning-ai>.
- Anonim. (2017). "Deep Learning." from <https://it.mathworks.com/discovery/deep-learning.html> (02/05/2017).
- Anonim. (2018). "Convolutional Neural Networks (CNN) Introduction'." from <https://indoml.com/2018/03/07/student-notes-convolutional-neural-networks-cnn-introduction/> (08/08/2018).
- Anonim. (2018). "Lattices with exponentially large kissing numbers." from <https://cp4space.wordpress.com/page/2/> (22/06/2018).
- Bakas, S., H. Akbari, A. Sotiras, M. Bilello, M. Rozycki, J. Kirby, J. Freymann, K. Farahani and C. Davatzikos (2017). "Segmentation labels and radiomic features for the pre-operative scans of the TCGA-GBM collection." *The Cancer Imaging Archive* **286**.
- Bakas, S., H. Akbari, A. Sotiras, M. Bilello, M. Rozycki, J. S. Kirby, J. B. Freymann, K. Farahani and C. Davatzikos (2017). "Advancing the cancer genome atlas glioma MRI collections with expert segmentation labels and radiomic features." *Scientific data* **4**: 170117.
- Bhandari, A. K., V. K. Singh, A. Kumar and G. K. Singh (2014). "Cuckoo search algorithm and wind driven optimization based study of satellite image segmentation for multilevel thresholding using Kapur's entropy." *Expert Systems with Applications* 41(7): 3538-3560.
- Çarkacı.N. (2018). "Derin Öğrenme Uygulamalarında En Sık kullanılan Hiper-parametreler." from <https://medium.com/deep-learning-turkiye/derin-ogrenme-uygulamalarinda-en-sik-kullanilan-hiper-parametreler-ece8e9125c4> (10/08/2018).
- Dong, H., G. Yang, F. Liu, Y. Mo and Y. Guo (2017). *Automatic brain tumor detection and segmentation using U-Net based fully convolutional networks*. Annual Conference on Medical Image Understanding and Analysis, Springer.
- Drozdal, M., E. Vorontsov, G. Chartrand, S. Kadoury and C. Pal (2016). The importance of skip connections in biomedical image segmentation. *Deep Learning and Data Labeling for Medical Applications*, Springer: 179-187.
- Fletcher-Heath, L. M., L. O. Hall, D. B. Goldgof and F. R. Murtagh (2001). "Automatic segmentation of non-enhancing brain tumors in magnetic resonance images." *Artificial Intelligence in Medicine* 21(1-3): 43-63.
- Havaei, M., A. Davy, D. Warde-Farley, A. Biard, A. Courville, Y. Bengio, C. Pal, P.-M. Jodoin and H. Larochelle (2017). "Brain tumor segmentation with deep neural networks." *Medical image analysis* 35: 18-31.
- He, K., X. Zhang, S. Ren and J. Sun (2016). *Deep residual learning for image recognition*.

- Proceedings of the IEEE conference on computer vision and pattern recognition.
- Juang, L. H. and M. N. Wu (2010). "MRI brain lesion image detection based on color-converted K-means clustering segmentation." *Measurement* 43(7): 941-949.
- Jones, T. L., T. J. Byrnes, G. Yang, F. A. Howe, B. A. Bell and T. R. Barrick (2014). "Brain tumor classification using the diffusion tensor image segmentation (D-SEG) technique." *Neuro-oncology* 17(3): 466-476.
- Kinga, D. and J. B. Adam (2015). A method for stochastic optimization. International Conference on Learning Representations (ICLR).
- Kızrak.A. (2018). "Evrişimli Sinir Ağları." from <https://medium.com/deep-learning-turkiye/deri%CC%87ne-daha-deri%CC%87ne-evri%C5%9Fimli-sinir-a%C4%9Flar%C4%B1-2813a2c8b2a9> (10/07/2018).
- Kurat, N. and N. Ozkaya (2014). Automaticly extracting brain tumor from MR image. Signal Processing and Communications Applications Conference (SIU), 2014 22nd, IEEE.
- Liu, J., J. Zheng, Q. Tang and W. Jin (2014). "Minimum error thresholding segmentation algorithm based on 3d grayscale histogram." *Mathematical Problems in Engineering* 2014.
- Long, J., E. Shelhamer and T. Darrell (2015). Fully convolutional networks for semantic segmentation. Proceedings of the IEEE conference on computer vision and pattern recognition.
- Menze BH, J. A., Bauer S, Kalpathy-Cramer J, Farahani K, Kirby J, Burren Y, Porz N, Slotboom J, Wiest R, Lanczi L, Gerstner E, Weber MA, Arbel T, Avants BB, Ayache N, Buendia P, Collins DL, Cordier N, Corso JJ, Criminisi A, Das T, Delingette H, Demiralp İ, Durst CR, Dojat M, Doyle S, Festa J, Forbes F, Geremia E, Glocker B, Golland P, Guo X, Hamamci A, Iftekharuddin KM, Jena R, John NM, Konukoglu E, Lashkari D, Mariz JA, Meier R, Pereira S, Precup D, Price SJ, Raviv TR, Reza SM, Ryan M, Sarikaya D, Schwartz L, Shin HC, Shotton J, Silva CA, Sousa N, Subbanna NK, Szekely G, Taylor TJ, Thomas OM, Tustison NJ, Unal G, Vasseur F, Wintermark M, Ye DH, Zhao L, Zhao B, Zikic D, Prastawa M, Reyes M, Van Leemput K (2015). "The multimodal brain tumor image segmentation benchmark (BRATS)." *IEEE transactions on medical imaging* 34(10): 1993.
- Parbhakar.A. (2016). "Deep Learning." from <https://www.linkedin.com/pulse/intuition-deep-neural-networks-abhishek-parbhakar/> (06/20/2018).
- Prema, V., M. Sivasubramanian and S. Meenakshi (2016). "Brain cancer feature extraction using Otsu's thresholding segmentation." *BRAIN* 6(3).
- Pereira, S., A. Pinto, V. Alves and C. A. Silva (2016). "Brain tumor segmentation using convolutional neural networks in MRI images." *IEEE transactions on medical imaging* 35(5): 1240-1251.
- Ramakrishna, R., A. Hebb, J. Barber, R. Rostomily and D. Silbergeld (2015). "Outcomes in reoperated low-grade gliomas." *Neurosurgery* 77(2): 175-184.
- Reddick, W. E., J. O. Glass, E. N. Cook, T. D. Elkin and R. J. Deaton (1997). "Automated segmentation and classification of multispectral magnetic resonance images of brain using artificial neural networks." *IEEE Transactions on medical imaging*

- 16(6): 911-918.
- Recognition, C. n. C. N. N. f. V. (2017). "Convolutional Neural Networks (CNNs / ConvNets)." from <http://cs231n.github.io/convolutional-networks/> (08/11/2017).
- Ruder.S (2017). "An overview of gradient descent optimization algorithms."
- Scheau.C. (2016). "Regularization in deep learning." from <https://chatbotslife.com/regularization-in-deep-learning-f649a45d6e0> (06/12/2018).
- Roy, P. K., A. Bhuiyan, A. Janke, P. M. Desmond, T. Y. Wong, W. P. Abhayaratna, E. Storey and K. Ramamohanarao (2015). "Automatic white matter lesion segmentation using contrast enhanced FLAIR intensity and Markov Random Field." *Computerized Medical Imaging and Graphics* 45: 102-111.
- Schwartzbaum, J. A., J. L. Fisher, K. D. Aldape and M. Wrensch (2006). "Epidemiology and molecular pathology of glioma." *Nature Reviews Neurology* 2(9): 494.
- Simard, P. Y., D. Steinkraus and J. C. Platt (2003). Best practices for convolutional neural networks applied to visual document analysis. null, IEEE.
- Simonyan, K. and A. Zisserman (2014). "Very deep convolutional networks for large-scale image recognition." *arXiv preprint arXiv:1409.1556*.
- Smoll, N. R., K. Schaller and O. P. Gautschi (2013). "Long-term survival of patients with glioblastoma multiforme (GBM)." *Journal of Clinical Neuroscience* 20(5): 670-675.
- Szegedy, C., W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke and A. Rabinovich (2015). Going deeper with convolutions. Proceedings of the IEEE conference on computer vision and pattern recognition.
- Şen.O. (2016, 2017). "beyin-tumorleri." from <http://www.orhansen.com/beyin-tumorleri> (16.01.2017).
- Zhang, W., R. Li, H. Deng, L. Wang, W. Lin, S. Ji and D. Shen (2015). "Deep convolutional neural networks for multi-modality isointense infant brain image segmentation." *NeuroImage* 108: 214-224.
- Zhou, C., L. Tian, H. Zhao and K. Zhao (2015). A method of two-dimensional Otsu image threshold segmentation based on improved firefly algorithm. *Cyber Technology in Automation, Control, and Intelligent Systems (CYBER)*, 2015 IEEE International Conference on, IEEE.

ÖZGEÇMİŞ

1984 yılında Erzurum’ da doğdu. İlk ve orta öğretimini Erzurum’ da tamamladı. 2002 yılında Uludağ Üniversitesi Bilgisayar ve Öğretim Teknolojileri Eğitimi bölümüne başladı. 2006 yılında bu bölümden mezun oldu. 2006 yılın da Milli Eğitim Bakanlığına Bilişim Teknolojileri Öğretmeni olarak atandı. 2013 yılında Atatürk Üniversitesi Elektrik-Elektronik Mühendisliği lisans programına başladı. 2017 yılında bu bölümden mezun oldu. Kocaeli ilinde Bilişim Teknolojileri ve Yazılım dersi öğretmenliği görevine halen devam etmektedir.